

Dự báo giá đối thủ và lượng hoá độ bất định cho bài toán định giá gọi xe

Nhóm R&D — GSM/XanhSM · Bộ dữ liệu TP.HCM

Phạm vi: 01/01–31/03/2026 · 1.724.714 lần báo giá · dữ liệu mô phỏng

Tóm tắt

Bài báo này trình bày một hệ thống dự báo mức giá mà đối thủ sẽ hiển thị cho một yêu cầu chuyển đi, tại thời điểm chỉ quan sát được giá đối thủ trễ 5–30 phút, kèm một khoảng tin cậy cho từng dự báo.

Hệ thống dựa trên quan sát rằng giá đối thủ có cấu trúc tích hai tầng — một mức giá nền theo cấu trúc chuyển, nhân với một hệ số phản ánh trạng thái thị trường. Chúng tôi học riêng từng tầng rồi nhân lại. Trên tập test tách theo thời gian, hệ thống đạt MAE 18.048đ và MAPE 14,74%, vượt baseline persistence 47,4%. Khoảng tin cậy dựng bằng conformal chuẩn hoá đạt coverage 89,81% ở mức danh mục 90%, với độ rộng trung bình 72.637đ.

Ngoài kết quả dự báo, chúng tôi báo cáo năm phân tích:

Thứ nhất, **phân rã sai số theo tầng**: 98,9% phương sai sai số nằm ở tầng giá cơ bản, trong khi tầng hệ số nhân đã đạt MAPE 1,42%. Điều này định vị lại toàn bộ nỗ lực cải thiện.

Thứ hai, **chẩn đoán theo chiều**: quãng đường là chiều giải thích sai số mạnh nhất ($\eta^2 = 0,0106$), mạnh hơn khoảng 100 lần so với thời điểm trong ngày ($\eta^2 \approx 0,0001$) — đi ngược trực giác thông thường rằng giờ cao điểm là chỗ khó.

Thứ ba, **so sánh model trên nhóm cố định**: khi mỗi model tự chia nhóm theo giá chính nó dự đoán, lợi thế của GAM ở nhóm giá cao bị phóng đại từ +1,65 lên +4,02 điểm. Chúng tôi trình bày cả hai con số và giải thích cơ chế tạo ra chênh lệch.

Thứ tư, **cơ chế phản ứng giá**: đo bằng đối chứng ghép cặp trên 1,72 triệu chuyển, cung–cầu là yếu tố mạnh nhất (+35,08%), và 80–96% tác động của các yếu tố thị trường đi qua tầng hệ số nhân.

Thứ năm, **giảm sai số ở nhóm khó**: sần sai số đo được là sần của *toàn tập*, không phải của từng nhóm. Đặt trọng số cao hơn cho chuyển hiếm cho kết quả âm tính — hai nhóm hiếm kéo ngược nhau. Ngược lại, trộn GAM với gradient boosting theo quãng đường cải thiện cả hai nhóm mà toàn tập không xấu đi: >15 km từ 18,12% xuống 15,61% và >300k từ 24,04% xuống 22,49% trên tập holdout hai tháng.

Mục lục

*Bấm vào mục để nhảy tới phần tương ứng. Trong Word/WPS còn có thanh điều hướng bên trái: **View** → **Navigation Pane**.*

- **1. Bài toán**
 - 1.1 Phát biểu
 - 1.2 Ba câu phần
 - 1.3 Đơn vị quan sát
 - 1.4 Tiêu chí và baseline
- **2. Dữ liệu**
 - 2.1 Phạm vi
 - 2.2 Bản chất dữ liệu và bốn hệ quả
 - 2.3 Chia tập theo thời gian
- **3. Cấu phần (i) — Yếu tố cấu thành giá**
 - 3.1 Cấu trúc hai tầng
 - 3.2 Phương pháp — đối chứng ghép cặp
 - 3.3 Bảng phản ứng giá
 - 3.4 Ngày lễ — thiếu cả cột lẫn hiện tượng
- **4. Cấu phần (ii) — Kiến trúc model**
 - 4.1 Vì sao hybrid hai tầng
 - 4.2 Đặc trưng
 - 4.3 Huấn luyện
- **5. Kết quả dự báo**
 - 5.1 Kết quả tổng
 - 5.2 Kiến trúc neural
 - 5.3 Sai số nằm ở tầng nào
- **6. Chẩn đoán — model khó ở đâu**
 - 6.1 Xếp hạng các chiều
 - 6.2 Chuyên dài khó, nhưng không phải model làm ầu
 - 6.3 Không có phím tắt
 - 6.4 Giới hạn thông tin của bộ feature
 - 6.5 So sánh model trên nhóm cố định
- **7. Cấu phần (iii) — Lượng hoá độ bất định**
 - 7.1 Ba phương pháp
 - 7.2 Coverage điều kiện
 - 7.3 Hiệu chỉnh Mondrian
 - 7.4 Ba kịch bản phân bổ độ rộng
 - 7.5 Sai lệch bất đối xứng
 - 7.6 Vì sao khoảng không hẹp lại được

- **8. Model có học đúng cơ chế giá không**
 - 8.1 Vấn đề
 - 8.2 Hiệu ứng trực tiếp và hiệu ứng tổng
 - 8.3 Kiểm chứng bằng cách cắt từng kênh
- **9. Hệ thống demo**
- **10. Giới hạn**
- **11. Hướng tiếp theo**
- **Phụ lục A — Quy ước tái lập**
- **Phụ lục B — Nhật ký đính chính**

1. Bài toán

1.1 Phát biểu

Tại thời điểm t , cho một yêu cầu chuyển đi với đặc trưng x (quãng đường, thời lượng, tuyến, dịch vụ, thời tiết, giờ), và lịch sử giá đối thủ quan sát được đến $t - \Delta$, cần dự báo mức giá đối thủ sẽ hiển thị:

$$\hat{p} = [p \mid x, \mathcal{H}_{t-\Delta}], \quad \Delta \in \{5, 10, 15, 30\} \text{ phút}$$

trong đó p là **target_shown_price**. Đồng thời dựng khoảng $[\ell, u]$ sao cho $\mathbb{P}(p \in [\ell, u]) \geq 1 - \alpha$ với $\alpha = 0,10$.

Độ trễ Δ là thứ khiến bài toán không tầm thường. Nếu quan sát được giá đối thủ ngay tại thời điểm cần ra quyết định thì chỉ cần đọc giá, không cần model. Dataset mô phỏng đúng ràng buộc thực tế: giá đối thủ luôn đến muộn.

1.2 Ba cấu phần

Đề bài được chia thành ba cấu phần, và bài báo trình bày kết quả theo đúng thứ tự này:

Cấu phần	Câu hỏi	Trình bày ở
(i)	Yếu tố nào cấu thành một mức giá, và đổi một yếu tố thì giá đổi bao nhiêu	§3
(ii)	Dự báo giá đối thủ chính xác đến đâu	§4, §5
(iii)	Mỗi dự báo đáng tin đến mức nào	§7

Cấu phần (i) không chỉ là phân tích mô tả. Nó quyết định kiến trúc model ở §4 và cho phép kiểm định xem model đã học đúng cơ chế hay chưa ở §8.

1.3 Đơn vị quan sát

Dataset có **hai mức hạt**, và lẫn lộn hai mức này là lỗi phổ biến nhất khi đọc số:

Mức	Khoá	Số dòng	Dùng khi
Forecast example	forecast_example_id	6.897.051	Huấn luyện và đánh giá model
Target request	target_request_id	1.724.714	Phân tích cấu thành giá

Mỗi [target_request](#) xuất hiện **4 lần**, một lần cho mỗi mức độ trễ. Nghĩa là khi phân tích yếu tố cấu thành giá, phải khử trùng theo [target_request_id](#) trước — nếu không, mỗi chuyển được đếm bốn lần và mọi kiểm định thống kê đều sai mức ý nghĩa.

1.4 Tiêu chí và baseline

Baseline là **persistence**: lấy luôn giá quan sát được gần nhất làm dự báo. Đây là cách làm ngây thơ nhất và là ngưỡng tối thiểu — một model không vượt được persistence thì không đáng vận hành.

Metric chính là MAPE, chia cho giá thật. Chúng tôi cũng báo cáo MAE và R^2 . Với khoảng tin cậy, hai metric là coverage (tỷ lệ giá thật rơi trong khoảng) và độ rộng trung bình. Hai metric này phải đọc cùng nhau: nói khoảng ra vô hạn thì coverage đạt 100% mà vô dụng.

2. Dữ liệu

2.1 Phạm vi

Kỳ dữ liệu	01/01/2026 – 31/03/2026 (90 ngày)
Số lần báo giá	1.724.714
Số forecast example	6.897.051
Số trường	72
Khu vực	3 điểm quanh Phú Mỹ Hưng, Quận 7
Dịch vụ	2 (Standard, Premium)
Nền tảng đối thủ	1

2.2 Bản chất dữ liệu và bốn hệ quả

Toàn bộ dữ liệu có `is_synthetic = True`. Đây không phải chi tiết phụ mà là ràng buộc định hình cách đọc mọi kết quả trong bài báo:

1. **Mọi con số mô tả hành vi của bộ sinh dữ liệu**, không phải bằng chứng về thị trường TP.HCM

thật. Khi chúng tôi viết "mưa làm giá tăng 9,70%", phát biểu đúng là "bộ sinh dữ liệu đặt hệ số mưa tương đương 9,70%".

2. **Cấu trúc sinh dữ liệu có thể đơn giản hơn thực tế**, nên độ chính xác đạt được ở đây là cận trên lạc quan cho dữ liệu thật.

3. **Một số hiện tượng thực tế không tồn tại trong dữ liệu**. §3.4 chỉ ra rằng ngày lễ không được mô

hình hoá.

4. **Không có nhãn chấp nhận/từ chối giá**, nên mọi phân tích về hành vi khách hàng chỉ dừng ở mô

hình cấu trúc có giả định, không train được.

2.3 Chia tập theo thời gian

Chia theo thời gian, không chia ngẫu nhiên. Chia ngẫu nhiên sẽ để chuyển của cùng một khoảng thời gian rơi vào cả train lẫn test, và vì các chuyển gần nhau về thời gian có giá tương quan mạnh, kết quả sẽ lạc quan giả.

Hai quy ước tập test cùng tồn tại trong dự án và cần nói rõ khi trích dẫn:

Tập	Số dòng	MAPE Hybrid	MAPE persistence
Test đầy đủ (4 độ trễ)	864.360	14,74%	28,18%
Test độ trễ 5 phút	216.090	14,65%	27,84%

Tập calibration dùng để hiệu chỉnh khoảng tin cậy gồm 615.908 chuyển (153.977 ở độ trễ 5 phút), tách riêng và model chưa từng thấy.

3. Cấu phần (i) — Yếu tố cấu thành giá

3.1 Cấu trúc hai tầng

Phân tích dữ liệu cho thấy giá đối thủ có dạng tích:

$$giá = giá cơ bản \times hệ số nhân$$

Giá cơ bản trung bình 103.642đ, hệ số nhân trung bình 1,165, cho giá cuối trung bình 121.367đ. Phân biệt hai tầng có ý nghĩa vận hành trực tiếp, vì mỗi tầng đòi hỏi một loại phản ứng khác nhau:

Tầng	Phản ánh	Bài toán tương ứng
Giá cơ bản	Cấu trúc chuyển — dài hơn, lâu hơn, tuyến khác	Ước lượng thời lượng, quy hoạch tuyến
Hệ số nhân	Trạng thái thị trường — cung cầu lệch	Điều phối cung

3.2 Phương pháp — đối chứng ghép cặp

Không chạy được thí nghiệm thật (không ai bật tắt mưa được), nên chúng tôi dùng đối chứng ghép cặp:

- 5. Chia dữ liệu thành các ô giống nhau ở mọi yếu tố khống chế.
- 6. Trong từng ô, so hai nhóm chỉ khác nhau ở đúng yếu tố đang xét.
- 7. Bình quân các ô theo số chuyển.

Mỗi yếu tố có bộ khống chế riêng, chọn để chặn đúng đường nhiễu đặc thù của nó:

Yếu tố xét	Khống chế	Vì sao
Trời mưa	quãng đường · giờ · cuối tuần	Mưa hay rơi buổi chiều — không khống chế giờ sẽ tính nhằm hiệu ứng cao điểm thành hiệu ứng mưa
Giờ cao điểm	quãng đường · thời tiết · cuối tuần	Cao điểm chỉ có ngày thường
Cung–cầu	quãng đường · giờ · thời tiết	Cung–cầu tương quan mạnh với giờ

Điểm mấu chốt: cùng một hàm chạy trên giá cuối, giá cơ bản và hệ số nhân. Nhờ vậy ba con số so sánh trực tiếp được với nhau, và cho biết yếu tố đó đi vào tầng nào.


3.3 Bảng phản ứng giá

Đo trên 1.724.714 chuyển độc lập (đã khử trùng theo [target_request_id](#)):

Yếu tố	Giá cuối	Qua giá cơ bản	Qua hệ số nhân	Phần qua hệ số nhân
Cung–cầu (Q1→Q5)	+35,08%	+5,60%	+27,90%	80%
Đường tắc (cùng quãng đường)	+16,52%	+13,43%	+2,70%	16%
Giờ cao điểm	+11,86%	+0,80%	+11,07%	93%


Trời mưa	+9,70%	+3,18%	+6,10%	63%
Cuối tuần	+6,30%	+0,24%	+6,38%	96%
Dịch vụ Premium	-1,29%	-1,02%	-0,25%	—

CG1 — Cung-cầu là yếu tố mạnh nhất, và nó đi gần như trọn vẹn qua HỆ SỐ NHÂN
Mọi yếu tố thị trường đều tác động qua tăng nhân giá; giá cơ bản gần như trơ



CG1_xep_hang_yeu_to

CG2 — Hai loại yếu tố, hai đường đi tách bạch
Cấu trúc chuyển (quãng đường, tắc đường) → giá cơ bản · Tín hiệu thị trường (giờ, cung-cầu, thời tiết) → hệ số nhân



CG2_cau_truc_vs_thi_truong

Ba điều rút ra:

Cung-cầu mạnh nhất, gấp ba lần giờ cao điểm. Giá về bản chất là kết quả của thay đổi yếu tố thị trường, không phải một bảng giá tĩnh cộng phụ phí.

Quy luật tách bạch. Yếu tố *thị trường* (cung-cầu, giờ, cuối tuần) đi qua hệ số nhân với tỷ lệ 80–96%. Yếu tố *cấu trúc chuyển* (quãng đường, tắc đường) đi qua giá cơ bản. Đây là bằng chứng thực nghiệm cho kiến trúc hai tầng ở §4, chứ không phải chọn kiến trúc rồi đi tìm số ủng hộ.

Mưa là ngoại lệ duy nhất — nó đi cả hai đường. Chuỗi nhân quả khép kín: mưa làm tăng cầu nên hệ số nhân tăng 6,10%, đồng thời mưa làm đường tắc nên chuyển lâu hơn và giá cơ bản tăng 3,18%. Điều này quay lại có ý nghĩa ở §8.

Quãng đường không đo bằng ghép cặp nhị phân vì nó là biến liên tục và chính là thứ đang được không chế ở mọi phép đo khác. Đo riêng: giá cơ bản trên mỗi km giảm từ 32.534đ (chuyến 1–2 km) xuống 13.168đ (chuyến 17–18 km), tức **−60%** — có chiết khấu rõ rệt cho chuyến dài.

3.4 Ngày lễ — thiếu cả cột lẫn hiện tượng

Dataset không có trường `public_holiday`. Quan trọng hơn, **hiện tượng cũng không tồn tại**. Kỳ dữ liệu chứa Tết Nguyên Đán 17/02/2026 — dịp giá gọi xe tăng mạnh nhất năm trong thực tế:


	Giá trung bình
Toàn kỳ 90 ngày	121.178đ (độ lệch chuẩn theo ngày 4.709đ)
Ngày Tết 17/02	116.173đ
Xếp hạng ngày Tết	81/90 (1 = đắt nhất)

Bộ sinh dữ liệu không mô hình hoá ngày lễ. Thêm cột `public_holiday` vào bộ hiện tại sẽ tạo ra một feature rỗng tín hiệu. Đây là ví dụ cho hệ quả (3) ở §2.2.

4. Cấu phần (ii) — Kiến trúc model

4.1 Vì sao hybrid hai tầng

Thay vì học thẳng giá cuối, chúng tôi học riêng hai tầng rồi nhân lại:



Ba lý do:

- Khớp cơ chế sinh giá thật** — §3.3 cho thấy hai nhóm yếu tố đi vào hai tầng khác nhau. Học riêng cho phép mỗi nhánh dùng bộ feature phù hợp.
- Chẩn đoán được** — khi sai, biết ngay sai ở tầng nào. §5.3 khai thác điều này.
- Hai tầng có độ khó rất khác nhau** — hệ số nhân đạt R^2 0,96 còn giá cơ bản chỉ 0,66. Gộp chung sẽ để bài toán dễ bị bài toán khó kéo xuống.

4.2 Đặc trưng

Điểm quan trọng nhất trong thiết kế feature là **chống rò rỉ**. Nhánh giá cơ bản dùng `latest_observed_base` — giá quan sát trễ đã bóc phần surge ra. Nhánh hệ số nhân dùng nhóm feature cung–cầu. Baseline dự đoán trực tiếp dùng `latest_observed_price` vốn đã gồm surge.

Nếu để nhánh giá cơ bản nhìn thấy giá đã gồm surge, nó sẽ học lại một phần hệ số nhân, và phép phân rã sai số ở §5.3 mất ý nghĩa vì hai tầng không còn độc lập.

Mọi feature lịch sử đều tính đến mốc $t - 1$, không bao giờ vượt qua thời điểm dự báo.

4.3 Huấn luyện

Thuật toán chính là gradient boosting trên cây (HistGradientBoosting cho cấu hình chốt, có đối chiếu LightGBM và XGBoost). Toàn bộ pipeline chạy lại trong khoảng 45 phút trên máy phát triển.

Chúng tôi đã thử tinh chỉnh siêu tham số bằng Optuna 40 trial — cải thiện thu được là **2 VND** trên MAE. Ném thêm 49 cột feature vào — cải thiện **6 VND**. Hai kết quả này là chỉ dấu sớm cho §6.

5. Kết quả dự báo

5.1 Kết quả tổng

Trên tập test đầy đủ 864.360 chuyên, tách theo thời gian:


Model	MAE	MAPE	R ²
Hybrid (chốt)	18.048đ	14,74%	~0,73
└ nhánh giá cơ bản	15.030đ	14,58%	0,6564
└ nhánh hệ số nhân	0,0232	1,90%	0,9609
XGBoost dự đoán trực tiếp	18.807đ	15,34%	
LightGBM dự đoán trực tiếp	18.809đ	15,34%	
HistGB dự đoán trực tiếp	18.834đ	15,36%	
GAM	19.170đ	15,70%	
Persistence (<i>baseline</i>)	33.683đ	28,18%	0,0191

Trên tập độ trễ 5 phút, model vượt persistence **47,4%**.

Hai điều đáng chú ý ngay ở bảng này. Thứ nhất, **kiến trúc hai tầng thắng dự đoán trực tiếp** khoảng 0,6 điểm MAPE — không lớn nhưng nhất quán trên cả ba thuật toán cây. Thứ hai, **bốn thuật toán khác nhau chỉ chênh nhau 1,9%**, tức lựa chọn thuật toán gần như không quyết định kết quả.

5.2 Kiến trúc neural

Chúng tôi đã dựng và huấn luyện một Transformer đọc thẳng chuỗi 32 báo giá gần nhất:



90.792 tham số, dự đoán hai đầu ra rồi nhân lại giống kiến trúc Hybrid.

Model	MAE	MAPE
Hybrid GBM	18.048đ	14,74%
Transformer	18.008đ	14,80%

Kết quả **hoà**: MAE tốt hơn 0,22% nhưng MAPE kém 0,06 điểm. Trước khi chạy Transformer đầy đủ, chúng tôi làm một phép thử rẻ bằng LightGBM để xem chuỗi thô có mang thêm thông tin so với nhóm thống kê tổng hợp hay không:

Bộ feature	MAE	MAPE
A. Chỉ feature cơ bản, không lịch sử giá	19.258đ	15,34%
B. + nhóm thống kê tổng hợp (<i>mốc</i>)	18.407đ	14,81%
C. + chuỗi 32 báo giá thô, bỏ nhóm tổng hợp	18.397đ	14,81%
D. + cả hai	18.402đ	14,81%

Lịch sử giá có giá trị thật (bỏ đi tệ hơn 4,4%), nhưng chuỗi thô và nhóm tổng hợp cho kết quả y hệt. Nhóm **mean/std/slope** cùng giá quan sát gần nhất đã là **thống kê đủ** cho chuỗi. Transformer đọc chuỗi vì thế không có gì mới để đọc — và kết quả thực nghiệm xác nhận đúng dự đoán đó.

5.3 Sai số nằm ở tầng nào

Vì giá là tích của hai tầng, lấy log là tách được sai số:

$$\log \hat{p}/p = \log \hat{b}/b + \log \hat{m}/m$$

Kiểm tra phép tách trên dữ liệu: sai lệch tối đa $5,8 \cdot 10^{-8}$, tức tách chuẩn.

	Giá cơ bản	Hệ số nhân	Tương tác
Tỷ trọng phương sai sai số	98,9%	1,1%	−0,0%


MAPE riêng tầng	14,58%	1,42%	—
-----------------	--------	-------	---

Tương quan giữa sai số hai tầng là $-0,001$, tức độc lập — xác nhận thiết kế chống rò rỉ ở §4.2 hoạt động đúng.

Thí nghiệm oracle: cho một tầng dự đoán hoàn hảo, giữ nguyên tầng kia.

Kịch bản	MAPE giá cuối	Giảm
Hiện tại	14,65%	—
Giá cơ bản hoàn hảo	1,42%	-90%
Hệ số nhân hoàn hảo	14,58%	-0%

TK1 — 98,9% sai số nằm ở tầng giá cơ bản, và tầng đó ĐÃ chạm trần thông tin
Sửa hệ số nhân về hoàn hảo không cải thiện gì; các chuyển giống hệt nhau vẫn lệch giá cơ bản ~18%



TK1_sai_so_o_tang_nao


Sửa hệ số nhân về hoàn hảo không cải thiện được gì. Toàn bộ dư địa nằm ở tầng giá cơ bản. Kết quả này có hệ quả trực tiếp lên kế hoạch: mọi feature thị trường thêm vào sẽ rơi vào tầng đã gần hoàn hảo, nên không nên kỳ vọng chúng cải thiện giá cuối.

6. Chẩn đoán — model khó ở đâu

6.1 Xếp hạng các chiều

Xếp hạng bằng η^2 , tỷ lệ phương sai sai số mà mỗi chiều giải thích được:

Chiều	η^2	MAPE thấp → cao
Quãng đường	0,0106	9,16% → 17,52%
Tuyến	0,0079	10,96% → 15,00%
Band giá	0,0015	13,46% → 18,55%
Giờ trong ngày	0,0001	14,48% → 14,85%
Thời tiết · cao điểm · cuối tuần	$\leq 0,0001$	biên độ $\leq 0,4$ điểm



Phát hiện đi ngược trực giác: giờ cao điểm — chiều mà mọi thảo luận về uncertainty thường xoay quanh — có $\eta^2 \approx 0$. Chiều thật sự quan trọng là quãng đường, mạnh hơn khoảng 100 lần. Tuyến đứng thứ hai nhưng tương quan 0,894 với quãng đường, tức cùng một nguyên nhân.

6.2 Chuyển dài khó, nhưng không phải model làm ầu

So sánh model với persistence theo từng nhóm quãng đường:

Quãng đường	MAPE model	MAPE persistence	Model vượt
<2 km	9,16%	28,04%	67,3%
5–8 km	14,99%	27,81%	46,1%
8–12 km	14,90%	26,33%	43,4%
>15 km	17,52%	52,66%	66,7%
Toàn tập	14,65%	27,84%	47,4%

Nhóm >15 km sai nhiều nhất và là nơi model đóng góp nhiều nhất so với baseline. Chuyển dài khó một cách nội tại — bản thân giá của chúng biến động mạnh hơn — chứ không phải model kém ở đó.

6.3 Không có phím tắt

Hai kiểm tra loại trừ các cách sửa rẻ tiền:

Không có thiên lệch hệ thống. Trung bình lệch +1,60% nhưng trung vị chỉ +0,01%, và tỷ lệ đoán cao hơn thật là 50,02%. Chênh lệch giữa trung bình và trung vị đến từ đuôi phải của phân phối giá, không phải model lệch. Trừ đi một hằng số sẽ làm hỏng nửa số chuyển đang đoán thấp.

Không có nhóm ngoại lai chi phối. 1% chuyển sai nhất (sai $\geq 53,1\%$) chỉ đóng góp 2,7% tổng sai số tuyệt đối. Không thể cải thiện đáng kể bằng cách xử lý riêng một nhóm nhỏ.



6.4 Giới hạn thông tin của bộ feature

Câu hỏi tự nhiên tiếp theo: giá cơ bản còn dao động bao nhiêu sau khi đã biết mọi thứ quan sát được về chuyển?

Chúng tôi ước lượng bằng phương pháp oracle: gom các chuyển giống hệt nhau ở mọi thuộc tính quan sát được, lấy trung bình nhóm làm dự đoán. Đó là mức chính xác tốt nhất về lý thuyết mà bất kỳ model nào chỉ dùng các thuộc tính đó có thể đạt.

Oracle được biết	MAPE	% dữ liệu phủ
Quãng đường (ô 0,5 km)	16,74%	100%
+ thời lượng (ô 5 phút)	15,22%	100%
+ tuyến	15,19%	99%
+ dịch vụ	14,98%	99%
◆ Model hiện tại	14,58%	100%

CG3 — Model giá cơ bản ĐÃ chạm trần thông tin
Các chuyển giống hệt nhau về mọi thuộc tính quan sát được vẫn có giá cơ bản lệch nhau ~18% — model không thể đoán phần đó



Model đạt 14,58%, tức đã ngang mức oracle — nhờ dùng thêm giá cơ bản quan sát trễ, thứ oracle không có. Bảng chứng hỗ trợ: các chuyến cùng 5,5–6,0 km và 15–20 phút (n = 83.427) vẫn có giá cơ bản trải rộng với hệ số biến thiên 18,7%.

Cần nói rõ giới hạn của phép đo này. Trung bình ô được tính in-sample nên đây là ước lượng **lạc quan** cho oracle. Ngoài ra nó chỉ nói về **bộ feature hiện tại** trên **bộ dữ liệu này** — không loại trừ khả năng feature mới hoặc dữ liệu thật cho kết quả khác. Cách đọc đúng là: trong phạm vi những gì đang quan sát được, dư địa cải thiện tăng giá cơ bản là nhỏ, nên nếu muốn tiến thêm thì phải thêm thông tin mới chứ không phải tinh chỉnh model.

Kết luận này nhất quán với bốn quan sát độc lập đã nêu: bốn thuật toán chênh nhau 1,9% (§5.1), Transformer hoà (§5.2), Optuna 40 trial cho +2 VND (§4.3), và 49 cột feature thêm cho +6 VND (§4.3).

6.5 So sánh model trên nhóm cố định

Ở nhóm chuyến dài và giá cao — hai nhóm §6.1 chỉ ra là khó nhất — chúng tôi kiểm tra xem GAM có lợi thế so với gradient boosting hay không.

Điểm phương pháp quan trọng: khi so sánh nhiều model, nhóm chuyến phải được cố định trước và giống nhau cho mọi model. Nếu để mỗi model tự chia nhóm theo giá chính nó dự đoán thì các model đang được chấm trên những tập chuyến khác nhau, và chênh lệch quan sát được lẫn cả hiệu ứng chọn mẫu.

Mức độ ảnh hưởng không nhỏ. Số chuyến rơi vào nhóm **>300k** theo ba cách chia:

Cách chia nhóm	Số chuyến >300k
Theo giá thật	869
Theo giá Hybrid dự đoán	327
Theo giá GAM dự đoán	330

Bảng dưới đây trình bày chênh lệch MAPE giữa GAM và Hybrid theo cả ba cách chia. Số dương nghĩa là GAM tốt hơn; khoảng tin cậy 95% tính bằng bootstrap 2.000 lần lấy mẫu lại.

Chia theo	Nhóm	n	Hybrid	GAM	Chênh (điểm)	CI 95%
Giá thật	>300k	869	23,67%	22,03%	+1,65	[+1,17, +2,12]
Giá Hybrid dự đoán	>300k	327	18,55%	14,52%	+4,02	[+2,74, +5,32]
Quãng đường	>15 km	660	17,52%	15,37%	+2,16	[+1,36, +2,91]
Quãng	12–15 km	2.045	15,26%	14,91%	+0,35	[+0,15,

đường						+0,56]
—	<i>Toàn tập</i>	216.090	14,65%	14,89%	−0,24	[−0,25, −0,22]

Ba kết luận:

Lợi thế của GAM ở nhóm giá cao là có thật nhưng nhỏ hơn báo cáo ban đầu. Con số +4,02 điểm tính trên nhóm chia theo giá model tự dự đoán bị phóng đại. Trên nhóm cố định theo giá thật, lợi thế còn +1,65 điểm. Cả hai đều có khoảng tin cậy không chứa 0, nhưng chỉ con số sau là so sánh công bằng.

Lợi thế ở chuyển dài vững hơn, vì quãng đường quan sát được và không phụ thuộc model nào. GAM tốt hơn +2,16 điểm ở nhóm >15 km và +0,35 điểm ở nhóm 12–15 km, cả hai đều có ý nghĩa thống kê. Đây là kết quả đáng tin cậy nhất trong bảng.

Trên toàn tập GAM kém hơn 0,24 điểm. Nên GAM không phải model thay thế mà là ứng viên cho một cách kết hợp có trọng số theo quãng đường. Hướng này đã được triển khai và trình bày ở §6.6.

6.6 Giảm sai số ở nhóm khó

§6.5 chỉ ra hai nhóm còn dư địa: chuyển >15 km và chuyển có giá thật >300k. Câu hỏi đặt ra là có giảm được sai số ở hai nhóm này mà không làm kết quả chung tệ đi hay không. Chúng tôi thử hai hướng, giữ nguyên model hiện tại làm mốc.

6.6.1 Đặt trọng số cao hơn cho chuyển hiếm

Hướng trực tiếp nhất: tăng `sample_weight` của chuyển hiếm khi huấn luyện, không đổi kiến trúc. Lưới $w \in \{1, 2, 3, 5, 10, 20\}$ × ba cách định nghĩa "chuyển hiếm" (>15 km · >300k · cả hai), tổng 48 lượt huấn luyện, chỉ huấn luyện lại nhánh giá cơ bản. Điểm neo $w = 1$ cho MAPE 14,6496%, trùng model mốc tới bốn chữ số thập phân.

Cách gán trọng số	w	>15 km	>300k	Toàn tập
— (mốc)	1	17,52%	23,67%	14,65%
Theo giá	10	21,69% (−4,17)	20,44% (+3,23)	14,71% (−0,06)
Theo quãng đường	20	18,51% (−0,98)	23,53% (+0,14)	14,66% (−0,01)

Số trong ngoặc là chênh so với mốc tính bằng điểm phần trăm, dấu dương nghĩa là tốt lên.

Kết quả **âm tính**, vì hai lý do khác nhau. Thứ nhất, gán trọng số theo quãng đường không cải thiện được chính nhóm nó nhắm tới: nhóm >15 km chỉ có 14.206 dòng huấn luyện và vốn nhiều, nên tăng trọng số chỉ khuếch đại nhiều — nhóm này xấu đi đơn điệu theo w ở cả ba cách gán.

Thứ hai, hai nhóm hiểm kéo ngược nhau: gán theo giá là cách duy nhất kéo >300k xuống, nhưng đổi lại >15 km mất 4,17 điểm. Không tồn tại mức trọng số nào cải thiện đồng thời cả hai.

6.6.2 Trộn GAM với gradient boosting theo quãng đường

Hướng thứ hai xuất phát từ §6.5: GAM chỉ thắng ở nhánh giá cơ bản của chuyển dài. Trước khi trộn, chúng tôi kiểm tra lợi thế đó có ổn định không, vì nhóm >15 km chỉ có 660 chuyển trong tập test. Dựng chín lần chia train/test theo thời gian: **tám trên chín lần** GAM tốt hơn với khoảng tin cậy không chứa 0, **không lần nào** gradient boosting tốt hơn có ý nghĩa. Không lần nào đảo chiều.

Dạng trộn đơn giản nhất — tuyến tính, trọng số của GAM tăng dần theo quãng đường, chỉ áp lên nhánh giá cơ bản:

$$\hat{p} = (1 - \alpha(d)) \hat{p}_{GBM} + \alpha(d) \hat{p}_{GAM}$$

với $\alpha(d) = 0$ khi $d \leq d_0$, tăng tuyến tính tới α_{max} trên đoạn $[d_0, d_1]$, và giữ nguyên α_{max} khi $d \geq d_1$. Tham số $d_0 = 6$ km, $d_1 = 14$ km, $\alpha_{max} = 0,8$ được chọn trên tháng 2026-01 rồi đánh giá trên hai tháng còn lại. Hàm $\alpha(d)$ liên tục nên giá không nhảy bậc tại ngưỡng.

Nhóm	n	GBM	Trộn	Chênh (điểm)	CI 95%
>15 km	428	18,12%	15,61%	+2,50	[+1,73, +3,36]
>300k	548	24,04%	22,49%	+1,55	[+1,04, +2,09]
Toàn tập	137.250	14,630%	14,616%	+0,014	[+0,01, +0,02]

Đo lại trên toàn bộ tập test với nhóm cố định (216.090 chuyển): >15 km 17,52% → 15,40%, >300k 23,67% → 22,24%, toàn tập 14,65% → 14,64%. Cả bốn cột đều có khoảng tin cậy không chứa 0.

Vì sao không dùng thẳng GAM. GAM đơn lẻ tốt hơn bản trộn ở cả hai nhóm hiểm (15,37% và 22,03%) nhưng toàn tập xấu đi 0,24 điểm — đánh đổi 216.090 chuyển lấy khoảng 1.500 chuyển là không có lợi.

Cơ chế, không phải trùng hợp thống kê. Cây quyết định không ngoại suy được: qua nhất cắt cuối cùng, dự đoán trở thành hằng số. Vùng >20 km chỉ chiếm 0,06% tập huấn luyện nên gần như không có nhất cắt nào ở đó. Đo bằng sai lệch có dấu thay vì sai số tuyệt đối: ở nhóm >25 km, giá thật trung bình là 463.286đ trong khi gradient boosting dự báo 328.995đ (−29,0%), GAM dự báo 462.720đ (−0,1%) và bản trộn 439.039đ (−5,2%). GAM khớp một hàm trơn theo quãng đường nên vẫn đi lên khi ra ngoài vùng dày dữ liệu.

Ý nghĩa chung. Sàn sai số ở §7.5 là sàn của *toàn tập*. Từng nhóm vẫn còn dư địa, nhưng chỉ khai thác được bằng cách đổi **dạng hàm** ở đúng vùng cần, không phải bằng cách đổi **trọng số** của cùng một dạng hàm.

7. Cấu phần (iii) — Lượng hoá độ bất định

7.1 Ba phương pháp

Giữ riêng tập calibration mà model chưa từng thấy, đo sai số trên đó, rồi lấy phân vị 90%:

Phương pháp	Coverage	Độ rộng TB	Bảo đảm lý thuyết
Conformal chuẩn hoá	89,81%	72.637đ	Hữu hạn mẫu, phân phối tự do
Quantile Regression	89,18%	75.977đ	Không
CQR	89,56%	76.546đ	Hữu hạn mẫu

Conformal chuẩn hoá được chọn làm mặc định: hẹp nhất và có bảo đảm lý thuyết.

$$q = \text{Quantile}_{0,90}(\{res_i\}_{i \in \text{calib}}), \quad [\ell, u] = \hat{p} \cdot (1 \pm q)$$

Kết quả $q = 30,07\%$, tức khoảng bằng giá dự đoán nhân $(1 \pm 30\%)$, coverage thực tế 89,81%.


Một chi tiết dễ sai: phần dư dùng để hiệu chỉnh phải chia cho **giá dự đoán** chứ không phải giá thật, vì tại thời điểm dự báo chưa biết giá thật.

7.2 Coverage điều kiện

Coverage trung bình 89,81% đạt mức danh mục. Nhưng trung bình che mất chênh lệch giữa các nhóm. Chia theo band giá dự đoán — nhóm biết được tại thời điểm ra quyết định:


Band giá dự đoán	n	Coverage	Độ rộng TB
<50k	2.716	92,42%	26.271đ
50–100k	66.035	90,52%	49.369đ
100–150k	102.331	89,39%	73.409đ
150–200k	37.353	89,61%	101.710đ
200–300k	7.328	89,52%	134.769đ
>300k	327	83,79%	201.658đ

PR1 — Khoảng bất định theo mức giá
Cùng $\pm 30\%$: chuyển ~44k ra khoảng 31-58k (rộng 27k) · chuyển ~326k ra khoảng 228-424k (rộng 196k)



PR1_khoang_theo_muc_gia

PR2 — Khoảng bất định theo bối cảnh: khung giờ và thời tiết
Khoảng nới ra theo MỨC GIÁ chứ không theo bối cảnh — coverage gần như phẳng qua 24 giờ và 4 loại thời tiết



PR2_uq_theo_boi_canh

Nhóm giá cao nhất bị phục vụ tệ nhất — hựt 6,2 điểm so với lời hứa. Đây cũng là nhóm mà một khoảng tin cậy sai gây thiệt hại lớn nhất về giá trị tuyệt đối.

Cần lưu ý về cách chia nhóm ở bảng này. Khác với §6.5, ở đây chúng tôi cố ý chia theo giá **dự đoán** chứ không phải giá thật. Lý do: coverage là lời hứa đưa ra *tại thời điểm dự báo*, nên nhóm phải định nghĩa bằng thông tin có sẵn lúc đó. Chia theo giá thật sẽ điều kiện hoá lên chính kết quả cần đo — những chuyển có giá thật rất cao đúng là những chuyển model đoán thấp, nên coverage đo được sẽ tụt xuống 47,99% một cách giả tạo. Đây là hai câu hỏi khác nhau và cần hai cách chia nhóm khác nhau: so sánh model dùng nhóm độc lập với model, đánh giá coverage dùng nhóm quan sát được lúc dự báo.

7.3 Hiệu chỉnh Mondrian


Conformal toàn cục cho một hệ số q chung. Mondrian cho mỗi nhóm một hệ số riêng.

Cách hiệu chỉnh	Nửa độ rộng	Coverage	So với gốc
Conformal toàn cục	$\pm 30,07\%$	89,81%	—
Mondrian theo band giá	$\pm 30,11\%$	89,84%	+0,11%
Mondrian theo quãng đường	$\pm 29,96\%$	89,77%	-0,37%

Mondrian theo giờ	±30,07%	89,78%	-0,02%
Mondrian theo thời tiết	±30,07%	89,80%	-0,01%

Mondrian không làm khoảng hẹp hơn — thay đổi độ rộng đều dưới 0,4%. Giá trị của nó nằm ở chỗ khác: làm coverage **đều** giữa các nhóm.

Lệch coverage lớn nhất giữa các nhóm	Toàn cục	Mondrian
Theo band giá	8,62 điểm	1,46 điểm
Theo quãng đường	12,61 điểm	2,53 điểm



Hai nhóm bị phục vụ tệ nhất được cải thiện rõ:

Nhóm	Coverage toàn cục	Coverage Mondrian
Band >300k	83,79%	91,13%
Quãng đường >15 km	82,58%	87,58%

Chi phí: vài giờ triển khai, không train lại model, tốn thêm 0,04% độ rộng. Đây là cải thiện có tỷ lệ lợi ích trên chi phí cao nhất trong toàn dự án.


7.4 Ba kịch bản phân bổ độ rộng

Một câu hỏi thường gặp: hai model có cùng MAE nhưng phân bổ độ rộng khoảng khác nhau thì khác nhau thế nào? Chúng tôi dựng ba kịch bản và chạy thật trên tập test:

Kịch bản	± cao điểm	Coverage cao điểm	± giờ thường	Coverage giờ thường
A · đều ±30%	30,0%	89,9%	30,0%	89,7%


B · $\pm 10\%$ cao điểm / $\pm 40\%$ thường	10,0%	42,3%	40,0%	96,3%
C · $\pm 40\%$ cao điểm / $\pm 10\%$ thường	40,0%	96,5%	10,0%	42,3%
Model thực tế	30,2%	90,1%	30,1%	89,7%

**TT5 — Ba kịch bản uncertainty mentor nêu, đặt lên cùng một ngày giá thật (2026-03-27, chuyến 4-6 km, gộp 30 phút)
Cùng một đường giá, cùng một dự đoán — chỉ khác cách phân bố độ rộng khoảng giữa cao điểm và giờ thường**



TT5_ba_kịch_ban_theo_thoi_gian

**TT6 — Kịch bản B và C hẹp hơn ở một khung giờ, nhưng trả giá bằng coverage sụp ở đúng khung đó
(toàn tập test, lag 5 phút)**



TT6_coverage_ba_kịch_ban

Model rơi đúng vào kịch bản A, tỷ lệ độ rộng cao điểm trên giờ thường là 1,004. Kịch bản B và C không tồn tại được trên bộ dữ liệu này: khung nào được cấp $\pm 10\%$ cũng chỉ giữ được 42,3%

coverage. Muốn hẹp ở cao điểm mà vẫn giữ 90% thì sai số ở cao điểm phải nhỏ hơn **thật sự** — mà §6.1 cho thấy sai số cao điểm và giờ thường gần như bằng nhau.

Một lưu ý về cách trình bày: trong hình chuỗi thời gian, điểm đánh dấu phải bám coverage **cấp chuyên**, không phải phép thử "đường trung bình có rơi ngoài dải trung bình hay không". Ở kịch bản B, đường giá trung bình vẫn nằm gọn trong dải suốt giờ cao điểm dù coverage thật chỉ 42% — đúng kiểu trung bình hoá che mất vấn đề.

7.5 Sai lệch bất đối xứng

Khoảng hiện tại đối xứng quanh giá dự đoán, nhưng sai lệch thực tế thì không:

	Tỷ lệ
Giá thật vượt cận trên	7,64%
Giá thật thấp hơn cận dưới	2,55%
Tỷ lệ giữa hai phía	3,00×

Model bỏ sót phía giá cao thường xuyên gấp ba lần phía giá thấp. Nguyên nhân là phân phối giá lệch phải: đuôi trên dài hơn đuôi dưới.

Chúng tôi đã thử phương án khoảng bất đối xứng — giữ tổng mức rủi ro 10% nhưng chia lại cho hai phía, dùng phân vị một phía trên tập calibration:

Chia rủi ro (dưới/trên)	q dưới	q trên	Coverage	Độ rộng	Vượt trên	Dưới
5,0% / 5,0% <i>(đối xứng theo phân vị)</i>	26,18%	34,76%	89,92%	73.598đ	—	—
4,0% / 6,0%	27,63%	32,61%	89,88%	72.753đ	—	—
3,0% / 7,0%	29,37%	30,70%	89,81%	72.541đ	7,30%	2,90%
2,5% / 7,5%	30,38%	29,80%	89,77%	72.676đ	7,81%	2,42%
2,0% / 8,0%	31,57%	28,93%	89,73%	73.071đ	8,34%	1,93%
<i>Đối xứng hiện tại ±30,07%</i>	30,07%	30,07%	89,81%	72.637đ	7,64%	2,55%

Kết quả là **âm tính**. Phương án tốt nhất (3%/7%) cho coverage y hệt 89,81% với độ rộng hẹp hơn 0,13% — thay đổi không đáng kể. Tỷ lệ bỏ sót hai phía cũng chỉ chuyển từ 7,64/2,55 sang 7,30/2,90. Và khi xét theo band giá, lệch coverage lớn nhất giữa các nhóm còn **tăng nhẹ** từ 6,21 lên 6,51 điểm.

Lý giải: khoảng hiện tại là **nhân tính** ($\hat{p} \cdot (1 \pm q)$) chứ không phải cộng tính, nên nó đã hấp thụ sẵn phần lớn độ lệch phải của phân phối giá. Phần bất đối xứng còn lại quá nhỏ để một phép dịch phân vị đơn giản khai thác được. Muốn xử lý triệt để thì phải cho độ bất đối xứng **thay đổi theo từng chuyển**, chứ không phải một cặp hằng số dùng chung.

Chúng tôi đã kiểm chứng nhận định cuối bằng cách dựng khoảng từ hai phân vị điều kiện [q05/q95](#) của quantile regression rồi hiệu chỉnh riêng từng phía — tức CQR bất đối xứng, trong đó độ rộng thay đổi theo từng chuyển thay vì dùng chung một cặp hằng số:

Phương án	Coverage	Độ rộng TB	Lệch coverage giữa band	Band >300k
Đối xứng hiện tại	89,81%	72.637đ	8,62 điểm	83,79%
Mondrian theo band giá + 3%/7%	89,84%	72.787đ (+0,21%)	6,58 điểm	83,49%
CQR bất đối xứng 3%/7%	89,04%	74.954đ (+3,2%)	1,55 điểm	88,03%

CQR là phương án duy nhất trong các phương án đã thử kéo được band >300k từ 83,79% lên 88,03%, tức gần sát mức danh nghĩa 90%, đồng thời giảm lệch coverage giữa các band từ 8,62 xuống 1,55 điểm. Cái giá là độ rộng trung bình tăng 3,2%.

Khác biệt bản chất nằm ở cách phân bổ độ rộng: phương án hiện tại cấp độ rộng tỷ lệ thuận với giá dự đoán, nên mọi chuyển đều nhận cùng một tỷ lệ $\pm 30,07\%$; CQR cấp độ rộng theo mức khó ước lượng được của từng chuyển. Đây là lý do nó xử lý được nhóm giá cao mà phép dịch phân vị không làm được.

7.6 Vì sao khoảng không hẹp lại được

Nếu biết trước độ khó của từng chuyển thì chỉ cần $\pm 14,68\%$ thay vì $\pm 30,07\%$ — dư địa lý thuyết -51% .

Nhưng độ khó từng chuyển không dự đoán được từ các thuộc tính quan sát được. Chúng tôi đã thử huấn luyện một model riêng để dự báo sai số của model chính, rồi dùng nó điều chỉnh độ rộng theo chuyển. Kết quả: cải thiện tốt nhất **$-0,37\%$** độ rộng, tương đương phương án Mondrian theo quãng đường mà đơn giản hơn nhiều.

Đây là lý do khoảng $\pm 30\%$ không phải dấu hiệu của hiệu chỉnh kém, mà phản ánh mức bất định thực sự còn lại trong dữ liệu sau khi model đã làm hết phần của nó.

8. Model có học đúng cơ chế giá không

8.1 Vấn đề

§3.3 đo phản ứng giá trên **dữ liệu thật**. Một câu hỏi kiểm định tự nhiên: model có tái hiện được những phản ứng đó không?

Khi so partial dependence của model với hiệu ứng đo bằng ghép cặp, xuất hiện khoảng cách khoảng 9 điểm phần trăm ở yếu tố mưa. Cách đọc ban đầu — và cũng là cách đọc sai — là "model chỉ bám giá quan sát trễ chứ không hiểu cơ chế".

8.2 Hiệu ứng trực tiếp và hiệu ứng tổng

Cách đọc đúng: hai con số đo hai đại lượng khác nhau.


Partial dependence đo **hiệu ứng trực tiếp** — đổi biến **weather** mà giữ nguyên mọi biến khác, gồm cả các biến trung gian như chỉ số cầu và thời lượng chuyển. Ghép cặp đo **hiệu ứng tổng** — bao gồm cả đường đi gián tiếp.

Mà §3.3 đã chỉ ra mưa tác động chủ yếu **qua** cầu và **qua** thời lượng. Nếu giữ nguyên hai biến trung gian đó thì hiệu ứng trực tiếp của mưa gần như bằng 0 — đúng như model thể hiện.

8.3 Kiểm chứng bằng cách cắt từng kênh


Để xác nhận, chúng tôi huấn luyện lại model sau khi bỏ đi từng nhóm feature:

Bỏ đi	MAPE tăng thêm	Độc
Chỉ bỏ giá quan sát trễ	+1,12%	Model tự bù bằng các kênh khác
Chỉ bỏ nhóm trung gian (cầu, thời lượng)	+1,49%	Model tự bù bằng giá quan sát trễ
Bỏ cả hai	+6,33%	Không còn gì để bù



PU1_rut_cai_nang

PU2 — Cùng đẩy giá lên, nhưng mưa và cao điểm đi qua hai cơ chế khác nhau



PU2 đi qua tăng nào

Bỏ riêng từng kênh gây thiệt hại nhỏ, bỏ cả hai gây thiệt hại lớn hơn tổng của hai phần riêng lẻ. Đó là dấu hiệu của **thông tin dư thừa giữa hai kênh** — model biết cơ chế qua nhiều đường và tự chuyển sang đường còn lại khi một đường bị cắt.

Cụ thể với mưa: khi rút giá quan sát trẻ ra, model tự bù lại **94%** hiệu ứng mưa bằng các feature còn lại. Kết luận "model chỉ bám giá quan sát" là sai, và chúng tôi đã ghi nhận đúng chính này.

9. Hệ thống demo

Toàn bộ kết quả được đóng gói thành một demo chạy trong trình duyệt, không cần cài đặt hay server. Demo chạy tập test qua model và mô phỏng từng chuyển trên bản đồ, hiển thị giá dự đoán, khoảng tin cậy, hệ số nhân dự đoán, rồi lộ ra giá thật và hệ số nhân thật khi chuyển kết thúc.

Ba bảng biểu đồ tương ứng ba cấu phần: độ chính xác dự báo và đối chiếu baseline; sai lệch phân rã theo mức giá, khung giờ, quãng đường và thời tiết; coverage và độ rộng khoảng theo từng nhóm.

Demo cho phép chọn khung giờ để mô phỏng riêng một khoảng thời gian trong ngày, và chuyển qua lại giữa hiệu chỉnh toàn cục và Mondrian. Thao tác thứ hai tái hiện trực tiếp kết quả §7.3: ở nhóm **>300k**, coverage nhảy từ khoảng 84% lên khoảng 91% ngay trên màn hình, kèm chi phí phải trả là khoảng rộng hơn.

10. Giới hạn

Năm giới hạn cần nêu rõ khi sử dụng kết quả của bài báo này.

Dữ liệu mô phỏng. Đây là giới hạn lớn nhất. Toàn bộ kết quả mô tả hành vi bộ sinh dữ liệu. Chưa có kiểm chứng nào trên dữ liệu thật, và §3.4 cho thấy bộ sinh dữ liệu bỏ sót ít nhất một hiện tượng quan trọng của thị trường thật (ngày lễ).

Phạm vi hẹp. Ba khu vực quanh một quận, hai dịch vụ, một nền tảng đối thủ, 90 ngày. Không đủ để kết luận về tính khái quát theo không gian hoặc theo mùa.

Đánh giá hồi cứu. Mọi con số đo trên một tập test cố định tách theo thời gian. Chưa có đánh giá tiến cứu trên dữ liệu mới đến theo thời gian thực, và chưa có kiểm tra độ ổn định qua nhiều lần chia dữ liệu khác nhau.

Tầng chấp nhận giá chỉ là giả định. Dữ liệu không có nhãn accept/reject nên tầng mô hình hoá hành vi khách hàng dựa trên mô hình cấu trúc có tham số giả định, không train và không kiểm chứng được. Mọi kết quả liên quan đến tầng này nằm ngoài phạm vi bài báo.

Trần thông tin ở §6.4 là ước lượng lạc quan và chỉ áp dụng cho bộ feature hiện tại. Trung bình ô tính in-sample. Kết luận đúng là dư địa nhỏ *trong phạm vi những gì đang quan sát được*, không phải là một giới hạn tuyệt đối.

11. Hướng tiếp theo

Bốn hướng nêu ở bản trước của bài báo này đều đã được thực hiện. Kết quả tóm tắt:

Hướng	Kết quả	Xem
Bật Mondrian theo quãng đường	✓ Lệch coverage giữa nhóm 12,61 → 2,53 điểm, tốn thêm 0,04% độ rộng	§7.3
Đặt trọng số cao hơn cho chuyển hiếm	✗ Âm tính — hai nhóm hiếm kéo ngược nhau	§6.6.1
Kiểm định lại lợi thế GAM qua nhiều lần chia	✓ Ổn định 8/9 lần chia ⇒ mở đường cho phương án trộn	§6.6.2
Khoảng bất đối xứng phụ thuộc chuyển	✓ CQR kéo band >300k lên 88,03%, đổi lại +3,2% độ rộng	§7.5

Ba hướng còn lại, xếp theo tỷ lệ lợi ích trên chi phí.

Đưa phương án trộn GAM–GBM vào pipeline chính. Kết quả ở §6.6.2 đã kiểm chứng trên tập holdout nhưng phần cài đặt còn nằm rời. Chi phí vài giờ, không huấn luyện lại.

Chốt giữa Mondrian và CQR cho khoảng dự báo. Hai phương án đánh đổi khác nhau: Mondrian rẻ hơn gần mười lần về độ rộng nhưng không kéo được band >300k lên, CQR làm được nhưng tốn 3,2% độ rộng. Lựa chọn phụ thuộc một tham số kinh doanh mà nhóm chưa có: mức độ rộng tăng thêm mà đội định giá chấp nhận để đổi lấy coverage đều giữa các nhóm.

Đo sai lệch có dấu khi vận hành. MAPE lấy trị tuyệt đối nên mất dấu. Đo bằng sai lệch có dấu cho thấy tổng thể model không thiên lệch (trung vị +0,01%, tỷ lệ dự báo cao 50,02%), nhưng có hai tình huống lệch rõ và cả hai đều nhận biết được trước khi dự báo: chuyển càng dài model càng dự báo thấp, và khi giá thị trường vừa tăng mạnh model dự báo thấp khoảng 10,6% do chỉ quan sát được giá trễ. Cả hai đều nên gắn cảnh báo ở đầu ra.

Ngoài ra, hai câu hỏi cần trả lời trước khi mở rộng phạm vi: dữ liệu thật có mức nhiễu báo giá tương đương bộ mô phỏng không, và có hiệu ứng ngày lễ không. Cả hai đều quyết định hướng đi và không thể trả lời từ bên trong bộ dữ liệu hiện tại.

Phụ lục A — Quy ước tái lập

Python	3.11.8
Thư viện chính	pandas, numpy, scikit-learn, lightgbm, xgboost, pygam, scipy, matplotlib
Thời gian chạy lại toàn bộ	~45 phút
Số notebook	59, đã chạy lại toàn bộ để kiểm tính tái lập

Hai quy ước dễ nhầm khi đối chiếu số:

Tập test tồn tại hai phiên bản — đầy đủ 864.360 dòng (4 độ trễ) và lag 5 phút 216.090 dòng. Chênh lệch MAPE giữa hai tập là 0,09 điểm. Khi trích dẫn phải nói rõ tập nào.

Sai số tương đối có hai mẫu số — chia cho giá thật khi báo cáo MAPE, chia cho giá dự đoán khi dựng khoảng conformal. Dùng nhầm mẫu số sẽ làm coverage lệch.

Đơn vị. Trường `quote_duration` tính bằng **giây**, không phải phút. Đây là lỗi đã từng mắc và làm sai một phần kết quả ở §6.4 trước khi phát hiện.

Phụ lục B — Nhật ký đính chính

Bốn phát biểu đã từng đưa ra và sau đó được sửa. Ghi lại để người đọc phân biệt được kết luận nào đã qua kiểm chứng lại.

#	Phát biểu ban đầu	Sửa thành	Nguồn
1	CQR có coverage điều kiện tốt nhất	Conformal chuẩn hoá hẹp hơn ở cùng coverage; CQR không vượt trội	§7.1
2	Model bám giá quan sát chứ không hiểu cơ chế	Khoảng cách 9 điểm là chênh lệch giữa hiệu ứng trực tiếp và hiệu ứng tổng	§8

3	Trần thông tin 14,84%	14,98% — do quote_duration tính bằng giây, không phải phút	§6.4
4	GAM tốt hơn Hybrid +4,02 điểm ở nhóm >300k	+1,65 điểm khi nhóm được cố định theo giá thật	§6.5