

Tài liệu kỹ thuật — Competitor Fare Forecasting (TP.HCM)

Dự án: Dự báo giá đối thủ và lượng hoá độ bất định ·

GSM/XanhSM · **Phạm vi dữ liệu:** 01/01–31/03/2026 · 1.724.714 lần báo giá · synthetic

0.1 Quy ước

Ký hiệu. Tài liệu viết bằng tiếng Việt nhưng giữ nguyên thuật ngữ tiếng Anh đã thành chuẩn ngành (*coverage, conformal, multiplier, elasticity...*) vì dịch ra sẽ khó đối chiếu với tài liệu tham khảo. Từ điển ở §0.3.

Số liệu. Mọi con số trong tài liệu đều tái lập được. Chỗ nào là giả định hoặc trích từ literature chưa xác minh đều được đánh dấu rõ. Đây là nguyên tắc xuyên suốt: người đọc phải phân biệt được điều gì đo được và điều gì giả định.


0.2 Tóm tắt điều hành

Bài toán

Dự báo target_shown_price — mức giá đối thủ sẽ hiển thị cho một yêu cầu chuyến đi — tại thời điểm chỉ quan sát được giá đối thủ trễ 5–30 phút. Kèm theo là một khoảng tin cậy cho mỗi dự báo.

Kiến trúc

Hệ thống 3 tầng, trong đó chỉ 2 tầng đầu là machine learning:



Kết quả chính

Hạng mục	Kết quả
MAPE giá cuối (test, lag 5')	14,65%
MAE giá cuối (test đầy đủ)	~18.048đ
Vượt baseline persistence	47,4%

Khoảng dự báo 90%	giá dự đoán $\times (1 \pm 30,1\%)$
Coverage thực tế	89,8%
MAPE nhóm >15 km — sau khi ghép GAM–GBM	17,52% → 15,40%
MAPE nhóm >300k — sau khi ghép GAM–GBM	23,67% → 22,24%

Ba kết luận đáng nói nhất

1. **Model đã chạm sàn sai số của bộ dữ liệu.** 98,9% phương sai sai số nằm ở tầng giá cơ bản, mà

tầng đó có trần lý thuyết 14,98% trong khi model đạt 14,58%. Các chuyển giống hệt nhau về mọi thuộc tính quan sát được vẫn có giá cơ bản lệch nhau CV 18,6%. Xem §7.5.

2. Mọi yếu tố thị trường đi qua tầng hệ số nhân — tầng đã gần hoàn hảo. Cung–cầu (+35,1%), giờ

cao điểm (+11,9%), cuối tuần (+6,3%) đều tác động $\geq 80\%$ qua hệ số nhân, mà hệ số nhân đã đạt MAPE 1,42%. $\Rightarrow$ Thêm feature thị trường không cải thiện được độ chính xác giá cuối. Xem §3.3, §7.5.

3. Model có học được cơ chế nhân quả, nhưng chỉ dùng khi cần. Ở lag 5' nó chép giá quan sát trễ;

rút cái nặng đó ra (lag 30') nó tự bù 94% hiệu ứng mưa. Xem §11.3.

4. **Sàn đó là sàn của toàn tập, không phải của từng nhóm.** Hai nhóm khó — chuyển >15 km và giá

thật >300k — vẫn còn dư địa, nhưng chỉ khai thác được bằng cách **đổi dạng hàm**, không phải bằng trọng số. Ghép GAM–GBM theo quãng đường cải thiện cả hai mà toàn tập không xấu đi; đặt trọng số cho chuyển hiểm thì hai nhóm kéo ngược nhau. Xem §13.5, §13.6.

Giới hạn lớn nhất

Dữ liệu là synthetic (`is_synthetic = True` toàn bộ). Mọi kết luận mô tả hành vi của bộ sinh dữ liệu, không phải thị trường TP.HCM thật. Ba giới hạn còn lại ở §18.

0.3 Từ điển thuật ngữ

Thuật ngữ	Nghĩa trong tài liệu này
Giá cơ bản (base price)	Phần giá phụ thuộc cấu trúc chuyển, = giá cuối / hệ số nhân
Hệ số nhân (multiplier)	Phần giá phụ thuộc trạng thái thị trường, target_shown_multiplier

Hybrid	Kiến trúc $\text{giá} = \text{Model_A}(\text{giá cơ bản}) \times \text{Model_B}(\text{hệ số nhân})$
Persistence	Baseline ngây thơ: dùng thẳng giá quan sát trễ làm dự đoán
Lag	Độ trễ của giá đối thủ quan sát được: 5, 10, 15, 30 phút
Coverage	Tỷ lệ giá thật rơi vào khoảng dự báo
Coverage điều kiện	Coverage tính riêng trong từng nhóm (band giá, quãng đường...)
Conformal	Phương pháp dựng khoảng có bảo đảm hữu hạn mẫu, không giả định phân phối
Mondrian	Conformal hiệu chỉnh riêng theo từng nhóm
η^2 (eta bình phương)	Tỷ lệ phương sai sai số giải thích được bởi một chiều
Ceteris paribus	Đổi một yếu tố, giữ nguyên phần còn lại
WTP	Willingness to pay — mức sẵn lòng chi trả
Elasticity ϵ	Độ co giãn của cầu theo giá

PHẦN I — BÀI TOÁN VÀ DỮ LIỆU

1. Định nghĩa bài toán

1.1 Ba cấu phần đề bài

#	Cấu phần	Thư mục	Trạng thái
(i)	Yếu tố nào ảnh hưởng giá và ảnh hưởng thế nào	analysis/	✓ Xong
(ii)	Model dự đoán giá đối thủ	model/train, model/evaluation	✓ Xong
(iii)	Lượng hoá độ bất định	model/uncertainty/	✓ Xong
(+)	Mức độ chấp nhận giá (mentor bổ sung)	model/acceptance/	⏸ Dừng ở v1

1.2 Hình thức hoá

Tại thời điểm t , cho một yêu cầu chuyển đi với đặc trưng x (quãng đường, thời lượng, tuyến, dịch vụ, thời tiết, giờ), và lịch sử giá đối thủ quan sát được đến $t - \Delta$, dự báo:

$$\hat{p} = [p \mid x, \mathcal{H}_{t-\Delta}], \quad \Delta \in \{5, 10, 15, 30\} \text{ phút}$$

trong đó $p = \text{target_shown_price}$. Đồng thời dựng khoảng $[\ell, u]$ sao cho $\mathbb{P}(p \in [\ell, u]) \geq 1 - \alpha$ với $\alpha = 0,10$.

Vì sao có độ trễ. Dataset mô phỏng tình huống thực tế: giá đối thủ không quan sát được tại đúng thời điểm cần ra quyết định. Đây là điểm khiến bài toán không tầm thường — nếu quan sát được ngay thì chỉ cần đọc giá, không cần model.

1.3 Đơn vị quan sát — điểm dễ sai nhất

Dataset có hai mức hạt, lẫn lộn hai mức này là lỗi phổ biến nhất:

Mức	Cột khoá	Số dòng	Dùng khi nào
Forecast example	<code>forecast_example_id</code>	6.897.051	Train và đánh giá model
Target request	<code>target_request_id</code>	1.724.714	Phân tích cấu thành giá

Mỗi `target_request` xuất hiện 4 lần trong bảng, một lần cho mỗi mức lag. Nghĩa là:

- **Khi train:** giữ nguyên 4 dòng — mỗi dòng là một bài toán dự báo khác nhau (thông tin đầu vào

khác nhau), hoàn toàn hợp lệ.

- **Khi phân tích giá:** bắt buộc `drop_duplicates("target_request_id")`, nếu không mỗi chuyển bị đếm 4 lần và mọi thống kê mô tả đều sai trọng số.

```
# Phân tích cấu thành giá – PHẢI khử trùng
d = pd.read_parquet(DATA, columns=COLS).drop_duplicates("target_request_id")
```

1.4 Tiêu chí thành công và baseline

Baseline bắt buộc vượt: `persistence` — dùng thẳng giá quan sát trễ làm dự đoán. Đây là baseline đúng cho bài toán này (không phải "dự đoán giá trung bình"), vì nó là thứ một hệ thống không có model sẽ làm.

	MAE	MAPE
Persistence (test đầy đủ)	33.683đ	28,18%
Hybrid (test đầy đủ)	18.048đ	14,74%
Persistence (test lag 5')	—	27,84%
Hybrid (test lag 5')	—	14,65%

⚠ Hai bộ số này khác nhau vì tập test khác nhau — xem §7.1. Khi trích dẫn phải nói rõ tập nào.

2. Dữ liệu

2.1 Nguồn và phạm vi

Tên	synthetic_quote_context_sandbox (TP.HCM)
Nguồn	Mentor cung cấp, 267 file .csv.gz chia theo 3 hex
Kỳ	01/01/2026 – 31/03/2026 (90 ngày)
Quy mô	1.724.714 báo giá $\times$ 4 lag = 6.897.051 dòng $\cdot$ 72 cột
Nền tảng	1 (Synthetic Competitor)
Dịch vụ	2 (Synthetic Standard Car , Synthetic Premium Car)
Khu vực	3 zone $\rightarrow$ 9 cặp tuyến
Thời tiết	4 loại (Clear , Clouds , Rain , Mist)

2.2 ⚠ Bản chất synthetic và bốn hệ quả

[is_synthetic = True](#) cho toàn bộ 6.897.051 dòng. Đây không phải chi tiết kỹ thuật nhỏ — nó điều kiện hoá mọi kết luận:

Hệ quả	Chi tiết
1. Kết luận mô tả simulator	Mọi phát hiện về hành vi giá là phát hiện về bộ sinh dữ liệu , không chứng minh được điều gì về thị trường TP.HCM thật
2. Mức nhiễu có thể không thật	Sàn sai số 14,6% (§7.5) là đặc tính của simulator. Dữ liệu thật có thể sạch hơn hoặc bẩn hơn
3. Thiếu hiện tượng thật	Ngày lễ không được mô hình hoá (§3.4). Có thể còn hiện tượng khác thiếu mà chưa phát hiện
4. Đa dạng thấp	3 khu vực, 2 dịch vụ, 1 nền tảng — không kiểm được tính khái quát

Đã ghi nhận ở [tai_lieu_tham_khao/03_final_point_pricing_report....](#) Phải nêu rõ khi báo cáo.

2.3 Từ điển trường — 72 cột theo vai trò

Nhóm	Số cột	Cột tiêu biểu
Định danh & thời gian	6	forecast_example_id , target_request_id , target_timestamp , evaluation_month
Chuyển đi	8	quote_distance , quote_duration , service_name , pickup/dropoff_zone_id , toạ độ

Địa điểm	5	<code>pickup/dropoff_location_name,</code> <code>pickup_hex_id_7</code>
Tín hiệu thị trường	5	<code>pricing_demand_index_5m_lag,</code> <code>pricing_supply_index_5m_lag,</code> <code>pricing_market_imbalance_5m_lag,</code> <code>pricing_avg_shown_multiplier_5m_lag,</code> <code>pricing_quote_count_5m_lag</code>
Thời tiết	20	<code>weather_main</code> (<i>dùng</i>) + 19 cột chi tiết (<i>không dùng</i>)
Quan sát trễ	9	<code>latest_observed_price,</code> <code>latest_observed_multiplier,</code> <code>actual_observation_age_minutes,</code> <code>persistence_prediction</code>
Lịch sử 60 phút	7	<code>history_60m_price_mean/std/min/max,</code> <code>history_60m_price_slope_per_minute,</code> <code>history_60m_multiplier_mean,</code> <code>history_60m_observation_count</code>
Nhãn (target)	3	<code>target_shown_price,</code> <code>target_shown_multiplier,</code> <code>target_price_per_km</code>
Phân chia & cò	9	<code>split, is_synthetic,</code> <code>requested_lag_minutes, scenario_id</code>

Từ điển chi tiết từng trường: [analysis/00a_tu_dien_70_truong.ipynb](#).

Không có trong dữ liệu (đã rà toàn bộ 72 cột):

- Nhãn `accept / reject` · outcome cuộc · `customer_id`
- `public_holiday`
- Chi phí biên, tỷ lệ ăn chia tài xế
- Thị phần

2.4 ⚠ Bốn bẫy dữ liệu đã vấp

Ghi lại để người sau không mất thời gian:

#	Bẫy	Triệu chứng	Cách đúng
1	<code>quote_duration</code> tính bằng giây , không phải phút	Nhãn hình ra "1125–1130 phút"; tốc độ tính ra 0,3 km/h	<code>kmh = quote_distance / (quote_duration / 3600)</code> ; ô 5 phút là <code>// 300</code>
2	Mỗi <code>target_request</code> lặp 4 lần theo lag	Thống kê mô tả sai trọng số	<code>drop_duplicates("target_request_id")</code> khi phân tích giá
3	<code>target_is_weekend</code> là	<code>unstack()</code> ném <code>KeyError</code> :	<code>.astype(bool)</code> trước khi dùng làm

	<code>int8</code> , không phải <code>bool</code>	<code>False</code>	khoá nhóm
4	Category codes lệch giữa train và test	XGBoost báo lỗi; HistGB/LightGBM im lặng đoán sai	Gọi <code>dat_categories(df)</code> một lần trên df đầy đủ trước khi chia tập

Bẫy 4 nguy hiểm nhất vì hai trong ba thuật toán không báo lỗi. Đã xử lý bằng `assert` trong `prep()` — xem §5.3.

Bẫy 1 đã làm sai một con số trong bản thảo (trần 14,84% thay vì 14,98%) — xem Phụ lục C.

2.5 Pipeline làm sạch

```
data/synthetic_data/*.csv.gz (267 file, 459,5 MB)
| model/00_chuan_bi_du_lieu.ipynb (~2,5 phút)
▼
data/hcm_train_ready.parquet (6.897.051 dòng × 72 cột, 368,6 MB)
|
▼ mọi notebook đọc từ đây
```

Notebook chuẩn bị làm: gộp file, ép kiểu (`float32/int8` để giảm bộ nhớ), sinh cột dẫn xuất (`gio_vn`, `thu_vn` theo múi giờ Việt Nam), gán `split`, và cố định danh mục category.

2.6 Chia tập theo thời gian

Tập	Số dòng	Vai trò
<code>train</code>	4.641.799	Huấn luyện
<code>validation</code>	774.984	Early stopping, chọn siêu tham số
<code>calibration</code>	615.908	Hiệu chỉnh khoảng bất định — model chưa từng thấy
<code>test</code>	864.360	Đánh giá cuối

Chia theo thời gian, không random. Lý do bắt buộc: dữ liệu có tự tương quan mạnh theo thời gian (giá 5 phút liên tiếp gần như nhau). Random split sẽ đặt các quan sát gần nhau về thời gian vào cả train lẫn test → rò rỉ → kết quả đẹp giả.

Tập **calibration** tách riêng là điều kiện để conformal prediction có bảo đảm hữu hạn mẫu: hệ số khoảng phải tính trên dữ liệu model chưa từng thấy. Dùng lại tập train sẽ cho khoảng hẹp giả.

3. Cấu thành giá — kết quả cấu phần (i)

Nguồn: tuan_4/04_CAU_THANH_GIA.ipynb, analysis/14_ceteris_paribus.ipynb · 1.724.714 chuyển độc lập

3.1 Cấu trúc hai tầng

$$\text{giá} = \text{giá cơ bản} \times \text{hệ số nhân}$$

Đây chính là cấu trúc *market signal multiplier* mà team mentor mô tả. Giá cơ bản trung bình 103.642đ, hệ số nhân trung bình 1,165 → giá cuối 121.367đ.

Phân biệt hai tầng có ý nghĩa vận hành trực tiếp:

Tầng	Phản ánh	Cần loại phản ứng nào
Giá cơ bản	Cấu trúc chuyển — dài hơn, lâu hơn, tuyến khác	Bài toán ước lượng thời lượng, quy hoạch tuyến
Hệ số nhân	Trạng thái thị trường — cung cầu lệch	Bài toán điều phối cung

3.2 Phương pháp — đối chứng ghép cặp

Không chạy được thí nghiệm thật (không ai bật/tắt mưa được), nên dùng đối chứng ghép cặp:

5. Chia dữ liệu thành các ô giống nhau ở mọi yếu tố không chế
6. Trong từng ô, so hai nhóm khác nhau đúng ở yếu tố đang xét
7. Bình quân các ô theo số chuyển

```
def ghep_cap(yeu_to, khong_che):  
    g = (d.groupby(khong_che + [yeu_to], observed=True)[cot]  
         .agg(["mean", "size"]).unstack(yeu_to).dropna())  
    n = g[("size", False)] + g[("size", True)]  
    w = n / n.sum()  
    return float(((g[("mean", True)] / g[("mean", False)] - 1) * w).sum())
```

Mỗi yếu tố có bộ không chế riêng, chọn để chặn đúng đường nhiễu đặc thù của nó:

Yếu tố xét	Không chế	Vì sao
Trời mưa	quãng đường · giờ · cuối tuần	Mưa hay rơi buổi chiều — không không chế giờ sẽ tính nhằm hiệu ứng cao điểm thành hiệu ứng mưa
Giờ cao điểm	quãng đường · thời tiết · cuối tuần	Cao điểm chỉ có ngày thường
Cung-cầu	quãng đường · giờ · thời tiết	Cung-cầu tương quan mạnh với giờ


Điểm mấu chốt: cùng một hàm chạy trên *gia*, *base*, *heso* — nên ba con số so sánh trực tiếp được và cho biết yếu tố đi vào tầng nào.

3.3 Bảng phản ứng giá

Yếu tố	Giá cuối	Qua giá cơ bản	Qua hệ số nhân	Phần qua HSN
Cung-cầu	+35,08%	+5,60%	+27,90%	80%


(Q1→Q5)				
Đường tắc (cùng quãng đường)	+16,52%	+13,43%	+2,70%	16%
Giờ cao điểm	+11,86%	+0,80%	+11,07%	93%
Trời mưa	+9,70%	+3,18%	+6,10%	63%
Cuối tuần	+6,30%	+0,24%	+6,38%	96%
Dịch vụ Premium	-1,29%	-1,02%	-0,25%	—
Ngày lễ	<i>không có</i>	—	—	—

CG1 — Cung-cầu là yếu tố mạnh nhất, và nó đi gần như trọn vẹn qua HỆ SỐ NHÂN
Mọi yếu tố thị trường đều tác động qua tăng nhân giá; giá cơ bản gần như trơ



CG1_xep_hang_yeu_to

CG2 — Hai loại yếu tố, hai đường đi tách bạch
Cấu trúc chuyến (quãng đường, tắc đường) → giá cơ bản · Tín hiệu thị trường (giờ, cung-cầu, thời tiết) → hệ số nhân



CG2_cau_truc_vs_thi_truong

Ba điều rút ra:

8. **Cung-cầu mạnh nhất** — gấp ba lần giờ cao điểm. Xác nhận trực tiếp cách team mentor nghĩ: giá

là kết quả của thay đổi yếu tố thị trường.

9. **Quy luật tách bạch.** Yếu tố *thị trường* (cung-cầu, giờ, cuối tuần) đi qua hệ số nhân; yếu tố

cấu trúc chuyển (quãng đường, tắc đường) đi qua giá cơ bản.

10. **Mưa là ngoại lệ duy nhất** — nó đi cả hai đường: vừa tăng cầu (hệ số nhân +6,10%), vừa làm

đường tắc khiến chuyển lâu hơn (giá cơ bản +3,18%). Chuỗi nhân quả khép kín: **mưa → tắc đường → thời lượng tăng → giá cơ bản tăng**, song song với **mưa → cầu tăng → hệ số nhân tăng**.

Quãng đường không đo bằng ghép cặp nhị phân (nó là biến liên tục và chính là thứ đang được không chế ở mọi phép đo khác). Đo riêng: giá cơ bản/km giảm từ 32.534đ (1–2 km) xuống 13.168đ (17–18 km), tức –60% — có chiết khấu rõ cho chuyển dài.

3.4 Ngày lễ — thiếu cả cột lẫn hiện tượng

Mentor nêu **public_holiday** đích danh. Hai vấn đề riêng biệt:

11. **Không có trường public_holiday** trong 72 cột.

12. **Hiện tượng cũng không có.** Kỳ dữ liệu chứa Tết Nguyên Đán 17/02/2026 — dịp giá gọi xe tăng

mạnh nhất năm ở thực tế. Kiểm trực tiếp:

	Giá TB
Toàn kỳ 90 ngày	121.178đ (sd theo ngày 4.709đ)
Ngày Tết 17/02	116.173đ
Xếp hạng ngày Tết	81/90 (1 = đắt nhất)

⇒ Bộ sinh dữ liệu không mô hình hoá ngày lễ. Nên câu hỏi cho mentor không phải *"bổ sung cột được không"* mà là *"dữ liệu thật có hiệu ứng ngày lễ không"*. Thêm cột vào bộ hiện tại sẽ tạo ra một feature rộng tín hiệu.

PHẦN II — MODEL

4. Kiến trúc

4.1 Vì sao hybrid hai tầng

Ba hướng đã cài đặt và so sánh:

Hướng	Cách làm	MAE (test đầy đủ)
Hybrid ★	Model_A(giá cơ bản) × Model_B(hệ số nhân)	18.048đ
Trực tiếp	Một model dự đoán thẳng giá cuối	18.834đ

GAM	Generalized Additive Model	19.170đ
-----	----------------------------	---------

Hybrid thắng dự đoán trực tiếp ở cả 24/24 giờ trong ngày — không phải thắng nhờ may mắn ở vài khung giờ.

Lý do hybrid tốt hơn không phải "hai model thì mạnh hơn một", mà là hai bài toán con có độ khó rất khác nhau:

Nhánh	R^2	MAPE	Nhận xét
Hệ số nhân	0,9609	1,90%	Gần như đã xong
Giá cơ bản	0,6564	14,58%	Nút thắt

Tách ra cho phép mỗi nhánh dùng bộ feature riêng phù hợp với bản chất của nó — hệ số nhân dùng tín hiệu cung-cầu, giá cơ bản dùng hình học chuyển. Gộp làm một model buộc phải dùng chung feature set và làm loãng tín hiệu.

Phân tích §3.3 giải thích vì sao cách tách này đúng về mặt cơ chế, không chỉ tiện về mặt kỹ thuật: hai tầng thật sự chịu tác động của hai nhóm yếu tố khác nhau.

4.2 Sơ đồ tầng đầy đủ

Xem §0.2. Nguyên tắc thiết kế chốt:

Tách bạch phần HỌC và phần GIÁ ĐỊNH.

Tầng	Bản chất	Có train?	Đánh giá bằng
1 Model giá	Machine learning	✓	MAE, R^2 , train/test split
1b Uncertainty	Hiệu chỉnh thống kê	✓ (trên calibration)	Coverage, độ rộng
2 Acceptance	Structural (McFadden)	✗	Phân tích độ nhạy

⚠ Không trộn tầng 1 và tầng 2. Trộn vào sẽ ra "model AUC 1,0" nguy trang — bằng chứng ở [acceptance/05_thu_nghiem_pseudo_label.ipynb](#), xem §12.2.

5. Đặc trưng (feature)

5.1 Bộ feature từng model

Định nghĩa tập trung tại [model/_common_train.py](#):

```
CAT = ["service_name", "pickup_location_name", "dropoff_location_name", "weather_main"]

# Nhánh giá cơ bản – dùng latest_observed_base (đã bỏ surge)
B_NUM = ["quote_distance", "quote_duration", "gio_vn", "latest_observed_base",
```

```

"history_60m_price_mean", "history_60m_price_std",
"history_60m_price_slope_per_minute", "latest_observed_quote_distance",
"latest_observed_quote_duration", "actual_observation_age_minutes"]

# Nhánh hệ số nhân – nhóm cung-cầu
M_NUM = ["pricing_market_imbalance_5m_lag", "pricing_demand_index_5m_lag",
"pricing_supply_index_5m_lag", "pricing_quote_count_5m_lag",
"latest_observed_multiplier", "gio_vn", "actual_observation_age_minutes"]

# Baseline dự đoán trực tiếp – dùng latest_observed_price (đã gồm surge)
D_NUM = ["quote_distance", "quote_duration", "gio_vn", "latest_observed_price",
"history_60m_price_mean", "history_60m_price_std",
"history_60m_price_slope_per_minute", "latest_observed_quote_distance",
"latest_observed_quote_duration", "actual_observation_age_minutes"]

```

Điểm thiết kế quan trọng: nhánh giá cơ bản dùng `latest_observed_base` (giá quan sát đã bỏ surge), nhánh hệ số nhân dùng `latest_observed_multiplier`. Nếu nhánh giá cơ bản dùng `latest_observed_price` thì surge sẽ bị đếm hai lần khi nhân hai nhánh lại.

Bốn feature đã loại nhờ p-value từ GAM (§13.3) — không có ý nghĩa thống kê.

5.2 Chống rò rỉ dữ liệu

Quy tắc	Cài đặt
Chỉ dùng thông tin có trước mốc cắt	Mọi feature <code>*_lag</code> , <code>latest_observed_*</code> , <code>history_60m_*</code> đều tính tại $t - \Delta$
Không dùng cột nhãn hoặc dẫn xuất từ nhãn	<code>target_shown_*</code> , <code>target_price_per_km</code> chỉ làm target
Chia tập theo thời gian	§2.6
Lịch sử giá reset theo tháng	Train riêng từng tháng — gộp lại là rò rỉ

Vai trò feature giá quan sát trễ. `latest_observed_price` / `_base` là feature mạnh nhất, và điều này có hệ quả sâu hơn về ngoài: model dùng nó như một đường tắt thay vì học cơ chế. Toàn bộ §11.3 dành cho việc đo hiện tượng này.

5.3 Bẫy mã hoá category

```

def dat_categories(df):
    """PHẢI gọi 1 lần trên df ĐẦY ĐỦ, TRƯỚC khi chia train/test."""
    for c in CAT:
        df[c] = df[c].astype("category")
    return df

```

Vì sao bắt buộc. Nếu để `prep()` tự cast trên từng tập con, pandas sinh danh mục riêng theo giá trị có trong tập con đó → train và test có mã số khác nhau cho cùng một giá trị (ví dụ `Clear` = 0 ở train nhưng = 1 ở test). Hậu quả:

Thuật toán	Biểu hiện
XGBoost	Báo lỗi <code>Found a category not in the training set</code> — dễ phát hiện

`prep()` có `raise TypeError` nếu phát hiện cột chưa được cast — chốt chặn để không ai quên.

6. Huấn luyện

6.1 Thuật toán và siêu tham số

Ba thuật toán cây được cài đặt song song để đối chứng:

```
HistGradientBoostingRegressor(max_iter=500, learning_rate=0.05,
                                l2_regularization=1.0, early_stopping=True, validation_fraction=0.1,
                                n_iter_no_change=20, categorical_features=CAT, random_state=42)
```

```
LGBMRegressor(n_estimators=800, learning_rate=0.03, num_leaves=63,
                subsample=0.8, colsample_bytree=0.8, reg_lambda=1.0, random_state=42)
```

```
XGBRegressor(n_estimators=800, learning_rate=0.03, max_depth=7,
               subsample=0.8, colsample_bytree=0.8, reg_lambda=1.0,
               tree_method="hist", enable_categorical=True, random_state=42,
               early_stopping_rounds=20, eval_metric="rmse")
```

Không tinh chỉnh siêu tham số sâu. Lý do có bằng chứng: Optuna 40 trial $\times$ 3 tháng chỉ cải thiện +2 VND. Ném hết 49 cột vào chỉ được 6 VND. Bốn thuật toán chênh nhau 1,9%. Tất cả đều chỉ về cùng một kết luận — model đã chạm trần dữ liệu (§7.5), nên đầu tư vào siêu tham số là lãng phí.

6.2 Quy trình và thời gian chạy

Bước	Notebook	Thời gian
Chuẩn bị dữ liệu	model/00_chuan_bi_du_lieu	~2,5 ph
Train giá cơ bản · hệ số nhân · trực tiếp	train/01-03	~9 ph
Train GAM đối chiếu	train/04	~13 ph
GAM transformed feature space	train/05	—
Train 21 model quantile	train/06	—
Sinh dữ liệu UQ	train/07	—
Tổng train		~21 ph

6.3 Artifact sinh ra

Thư mục	Dung lượng	Nội dung
---------	------------	----------

QuantileLGBM/	67,9 MB	21 model quantile (7 phân vị × 3 tháng)
XGBoost/	63,2 MB	giá cuối · giá cơ bản · hệ số nhân
LightGBM/	41,5 MB	như trên
HistGB/	28,0 MB	như trên + 2 model riêng cho UQ
GAM/	1,1 MB	3 nhánh GAM + encoder

⚠️ [.gitignore](#) loại [*.joblib](#) và [*.parquet](#) — không artifact nào có trong git. Xoá là mất hân, chỉ khôi phục bằng cách chạy lại notebook.

7. Đánh giá

7.1 Định nghĩa metric — và hai tập test

```
MAE = mean(|y - ŷ|)
RMSE = sqrt(mean((y - ŷ)²))
R² = 1 - SS_res / SS_tot
MAPE = mean(|y - ŷ| / y) × 100 # chia cho GIÁ THẬT
```

⚠️ Hai quy ước tập test cùng tồn tại trong dự án. Đây là nguồn nhầm lẫn phổ biến khi đối chiếu số giữa các báo cáo:

Tập	Số dòng	Dùng ở	MAPE hybrid	MAPE persistence
Test đầy đủ (4 lag)	864.360	Báo cáo tuần 2–3	14,74%	28,18%
Test lag 5'	216.090	Tuần 4, uncertainty	14,65%	27,84%

Cả hai đều đúng. Lag 5' dễ hơn một chút nên MAPE thấp hơn. Khi trích dẫn phải nói rõ tập nào. Ngoài ra, cần phân biệt hai mẫu số khi tính sai số tương đối:

Ký hiệu	Công thức	Dùng khi
sai		$\hat{y} - y$
res		$\hat{y} - y$

7.2 Kết quả tổng

Model	MAE	MAPE	R²
Hybrid	18.048đ	14,74%	~0,73
└─ Giá cơ bản	15.030đ	14,58%	0,6564

└─ Hệ số nhân	0,0232	1,90%	0,9609
XGBoost trực tiếp	18.807đ	15,34%	
LightGBM trực tiếp	18.809đ	15,34%	
HistGB trực tiếp	18.834đ	15,36%	
GAM	19.170đ	15,70%	
— Persistence (<i>baseline</i>)	33.683đ	28,18%	0,0191

Trên tập lag 5': model vượt persistence 47,4%.

7.3 Sai số nằm ở tầng nào

Nguồn: tuan_4/00_TONG_HOP.ipynb · test lag 5'

Vì **giá = cơ bản × hệ số**, lấy log là tách được sai số theo tầng:

$$\log p/p = \log b/b + \log m/m$$

Kiểm tra phép tách: sai lệch tối đa $5,8 \cdot 10^{-8} \Rightarrow$ tách chuẩn.


	Giá cơ bản	Hệ số nhân	Tương tác
Tỷ trọng phương sai sai số	98,9%	1,1%	−0,0%
MAPE riêng tầng	14,58%	1,42%	—

Tương quan giữa sai số hai tầng: −0,001 — độc lập.

Thí nghiệm oracle — cho một tầng dự đoán hoàn hảo, giữ nguyên tầng kia:

Kịch bản	MAPE giá cuối	Giảm
Hiện tại	14,65%	—
Giá cơ bản hoàn hảo	1,42%	−90%
Hệ số nhân hoàn hảo	14,58%	−0%

TK1 — 98,9% sai số nằm ở tầng giá cơ bản, và tầng đó ĐÃ chạm trần thông tin
Sửa hệ số nhân về hoàn hảo không cải thiện gì; các chuyển giống hệt nhau vẫn lệch giá cơ bản ~18%



TK1_sai_so_o_tang_nao

⇒ Sửa hệ số nhân về hoàn hảo không cải thiện được gì. Toàn bộ dư địa nằm ở tầng giá cơ bản.

7.4 Chẩn đoán — model fail ở đâu

Nguồn: *evaluation/09_chan_doan_model.ipynb, tuan_4/02*


Xếp hạng các chiều bằng η^2 — tỷ lệ phương sai sai số mà chiều đó giải thích được:

Chiều	η^2	MAPE thấp → cao	Kết luận
Quãng đường	0,0106	9,16% → 17,52%	● Chỗ hỏng nặng nhất
Tuyến	0,0079	10,96% → 15,00%	● Tương quan 0,894 với quãng đường ⇒ cùng nguyên nhân
Band giá	0,0015	13,46% → 18,55%	Sửa bằng Mondrian
Giờ trong ngày	0,0001	14,48% → 14,85%	
Thời tiết · cao điểm · cuối tuần	≤0,0001	biên độ ≤0,4 điểm	Gần như vô can

Phát hiện đi ngược trực giác: giờ cao điểm — thứ mentor nêu ba kịch bản uncertainty quanh nó — có $\eta^2 \approx 0$. Chiều thật sự quan trọng là quãng đường, mạnh gấp ~ 100 lần.

Nhưng chuyển dài không phải model làm ầu. So với persistence theo từng nhóm:

Quãng đường	MAPE model	MAPE persistence	Model vượt
<2 km	9,16%	28,0%	67,3%
4–6 km	14,95%	29,7%	49,7%
8–10 km	14,90%	26,0%	42,8%
>15 km	17,52%	52,6%	66,7%
Trung bình	14,65%	27,84%	47,4%



Nhóm **>15 km** sai nhiều nhất và là nơi model đóng góp nhiều nhất. ⇒ Chuyển dài khó một cách nội tại, không phải model kém ở đó. Hệ quả lập kế hoạch: đừng đổ công "sửa chuyển dài" trên cùng bộ feature.

Không có thiên lệch hệ thống. Trung bình lệch +1,60% nhưng trung vị +0,01% và tỷ lệ đoán cao hơn thật 50,02% ⇒ do đuôi phải của phân phối giá, không phải model lệch. Trừ đi một hằng số sẽ làm hồng nửa số chuyển đoán thấp.

Không có nhóm ngoại lai chi phối. 1% chuyển sai nhất (sai $\geq 53,1\%$) chỉ đóng góp 2,7% tổng sai số tuyệt đối. Không có phím tắt.

7.5 Trần thông tin — sần sai số của bộ dữ liệu



Đây là kết quả quan trọng nhất của tài liệu. Nguồn: tuan_4/04 §5, tuan_4/00

Câu hỏi: giá cơ bản còn dao động bao nhiêu sau khi đã biết mọi thứ quan sát được về chuyển?

Phương pháp oracle: gom các chuyển giống hệt nhau ở mọi thuộc tính quan sát được, lấy trung bình nhóm làm dự đoán. Đó là mức chính xác tốt nhất về lý thuyết mà bất kỳ model nào chỉ dùng các thuộc tính đó có thể đạt.

Oracle được biết	MAPE trần	% dữ liệu
Quãng đường (ô 0,5 km)	16,74%	100%
+ thời lượng (ô 5 phút)	15,22%	100%
+ tuyến	15,19%	99%
+ dịch vụ	14,98%	99%
◆ Model hiện tại	14,58%	100%

CG3 — Model giá cơ bản ĐÃ chạm trần thông tin
 Các chuyến giống hệt nhau về mọi thuộc tính quan sát được vẫn có giá cơ bản lệch nhau ~18% — model không thể đoán phần đó



CG3_tran_thong_tin_gia_co_ban

Model đã vượt trần — nhờ dùng thêm giá cơ bản quan sát trễ, thứ oracle không có.

Và trần này còn được ước lượng lạc quan: trung bình ô tính in-sample nên trần thật cao hơn. Kết luận vì thế càng chắc.

Bảng chứng bổ trợ: các chuyến cùng 5,5–6,0 km và 15–20 phút (n = 83.427) vẫn có giá cơ bản trải rộng CV 18,7%. Thêm tuyến vào chỉ hạ trần 0,03 điểm (15,22% → 15,19%).

Kết luận: giá cơ bản có một thành phần nhiễu ngẫu nhiên theo từng báo giá, không có quy luật để học. MAPE ~14,6% là sàn của bộ dữ liệu này.

Kết luận này khớp với ba bằng chứng độc lập đã có từ trước:

Bằng chứng	Nguồn
4 thuật toán chênh nhau 1,9%	§7.2
Thu hẹp quãng đường xuống 2 mét, hệ số biến thiên giá không giảm	B5_cv_khong_giam.png
Optuna 40 trial → +2 VND; ném 49 cột → +6 VND	§6.1
Transformer 90.792 tham số, đọc thẳng chuỗi 32 báo giá → hoà	§13.4

PHẦN III — UNCERTAINTY (CẤU PHẦN iii)

8. Ba phương pháp

Giữ riêng 615.908 chuyển model chưa từng thấy (tập calibration) → đo sai số → lấy phân vị 90%.

Phương pháp	Coverage	Độ rộng TB	Bảo đảm lý thuyết
Conformal chuẩn hoá ★	~89,6%	~72.700đ	Hữu hạn mẫu, phân phối tự do
Quantile Regression (thô)	89,18%	75.977đ	✗ Không
CQR	89,56%	76.546đ	Hữu hạn mẫu

Conformal chuẩn hoá làm mặc định — hẹp nhất và có bảo đảm.

Công thức. Trên calibration, tính $\text{res} = |\hat{y} - y| / \hat{y}$ cho từng chuyển, lấy phân vị 90%:

$$q = \text{Quantile}_{0,90}(\{\text{res}_i\}_{i \in \text{calib}}), \quad [\ell, u] = \hat{p} \cdot (1 \pm q)$$

Kết quả: $q = 30,07\% \rightarrow$ khoảng = giá dự đoán $\times (1 \pm 30\%)$, coverage thực tế 89,81%.

Dùng res (chia cho $\hat{y}$) chứ không phải sai (chia cho y) vì lúc dự báo chưa biết y — xem §7.1.

9. Hiệu chỉnh Mondrian


Conformal toàn cục cho một hệ số q chung. Mondrian cho mỗi nhóm một hệ số riêng.

Cách hiệu chỉnh	Nửa độ rộng	Coverage	Hẹp hơn gốc
Conformal toàn cục	$\pm 30,07\%$	89,81%	—
Mondrian theo band giá	$\pm 30,11\%$	89,84%	+0,11%
Mondrian theo quãng đường	$\pm 29,96\%$	89,77%	-0,37%
Mondrian theo giờ	$\pm 30,07\%$	89,78%	-0,02%
Mondrian theo thời tiết	$\pm 30,07\%$	89,80%	-0,01%

Mondrian không làm khoảng hẹp hơn. Nhưng nó làm khoảng đều hơn — và đó mới là lý do dùng:

Lệch coverage tối đa giữa các nhóm	Toàn cục	Mondrian
Theo band giá	8,62 điểm	1,46 điểm

Theo quãng đường	12,61 điểm	2,53 điểm
------------------	------------	-----------



QD1_mondrian_lam_deu

Nhóm bị phục vụ tệ nhất dưới hiệu chỉnh toàn cục:

Nhóm	Coverage toàn cục	Coverage Mondrian
Band >300k	83,79%	91,13%
Quãng đường >15 km	82,58%	87,58%

Đây là chuyển đắt tiền nhất — nơi sai một khoảng tin cậy tổn nhiều nhất. Chi phí sửa: vài giờ, không train lại, tổn thêm 0,04% độ rộng.


Khuyến nghị vận hành: bật Mondrian theo quãng đường.

10. Coverage điều kiện và ba kịch bản

Mentor nêu ba model có cùng MAE nhưng phân bố độ rộng khác nhau. Chạy thật trên tập test:


Kịch bản	± cao điểm	Coverage CĐ	± giờ thường	Coverage GT
A · đều ±30%	30,0%	89,9%	30,0%	89,7%
B · ±10% CĐ / ±40% GT	10,0%	42,3%	40,0%	96,3%
C · ±40% CĐ / ±10% GT	40,0%	96,5%	10,0%	42,3%
Model của mình	30,2%	90,1%	30,1%	89,7%

**TT5 — Ba kịch bản uncertainty mentor nêu, đặt lên cùng một ngày giá thật (2026-03-27, chuyến 4-6 km, gộp 30 phút)
Cùng một đường giá, cùng một dự đoán — chỉ khác cách phân bố độ rộng khoảng giữa cao điểm và giờ thường**



TT5_ba_kịch_ban_theo_thoi_gian

**TT6 — Kịch bản B và C hẹp hơn ở một khung giờ, nhưng trả giá bằng coverage sụp ở đúng khung đó
(toàn tập test, lag 5 phút)**



TT6_coverage_ba_kich_ban

Ba điều rút ra:

- Con số $\pm 30\%$ mentor đưa ra trùng phóc — chạy thật cho coverage 89,7%.
- Model là kịch bản A, tỷ lệ độ rộng cao điểm / giờ thường = 1,004.
- B và C không tồn tại được trên tập này: khung được cấp $\pm 10\%$ chỉ giữ 42,3% coverage.

Muốn hẹp

ở cao điểm mà vẫn giữ 90% thì sai số ở cao điểm phải nhỏ hơn thật sự — mà §7.4 cho thấy sai số cao điểm và giờ thường bằng nhau.

Cách trình bày quan trọng: trong hình chuỗi thời gian, chấm đỏ bám coverage cấp chuyển, không phải phép thử "đường trung bình rơi ngoài dải trung bình". Lý do: ở kịch bản B, đường

giá trung bình vẫn nằm gọn trong dải suất cao điểm dù coverage thật chỉ 42% — đúng kiểu trung bình hoá che mất vấn đề.

11. Vì sao không thu hẹp được khoảng


11.1 Trần lý thuyết

Nếu biết trước độ khó từng chuyến thì chỉ cần $\pm 14,68\%$ thay vì $\pm 30,07\%$ — dư địa -51% .

11.2 Nhưng không với tới được

Mọi cách hiệu chỉnh đều dựa trên một ý tưởng: cấp khoảng hẹp cho chuyến dễ, rộng cho chuyến khó. Ý tưởng đó chỉ chạy được nếu biết trước chuyến nào khó.

Tương quan hạng (Spearman) với độ lớn sai số	
Quãng đường	+0,0509
Giá dự đoán	+0,0473
Thời lượng	+0,0509
Tốc độ trung bình	+0,0225
GBM dự đoán độ khó (4 feature)	+0,0530




Train hẳn một GBM để dự đoán độ lớn sai số → tương quan hạng với sai số thật chỉ 0,053. Đám mây điểm là một cột dựng đứng: GBM đoán chuyến nào cũng khó ngang nhau ($\sim 29\text{--}31\%$) trong khi sai số thật trải từ 0% tới hơn 60%.

Khoảng $\pm 30\%$ không phải lỗi hiệu chỉnh. Nó là ảnh phản chiếu trung thực của MAPE 14,65%. Muốn khoảng hẹp thì model phải sai ít hơn — mà §7.5 cho thấy model đã chạm sàn.

11.2b Khoảng rộng vì thị trường động, hay vì nhiều?

Một đề xuất tự nhiên chưa bị loại: "quan sát giá nhanh hơn thì khoảng hẹp lại". Kiểm trực tiếp vì dữ liệu có sẵn bốn mức độ trễ:

Độ trễ	MAPE model	MAPE persistence	Nửa độ rộng	Coverage
5'	14,65%	27,84%	±30,07%	89,81%
10'	14,69%	28,03%	±30,05%	89,66%
15'	14,74%	28,19%	±30,08%	89,54%
30'	14,91%	28,67%	±30,19%	89,24%



Rút độ trễ 30' → 5' chỉ cải thiện MAPE 0,26 điểm; độ rộng gần như không đổi (−0,4%). Để so sánh, **persistence** — thứ hoàn toàn phụ thuộc độ tươi của giá quan sát — tụt đi 3,0%. Phép đo có đủ độ nhạy; nó cho thấy model gần như miễn nhiễm với độ trễ.

Ba nguồn biến động, tách bạch:

Nguồn	Độ lớn	Model xử lý được không
Nhịp thị trường — hệ số nhân theo giờ	biên độ 87,2% (0,851 → 1,592)	✓ Có — MAPE 1,42% ở tầng này
Nhiều ngang — giữa các báo giá cùng bối cảnh	CV 18,5%	✗ Không feature nào giải thích được
Trôi theo thời gian — 5' → 30'	0,26 điểm MAPE	Quá nhỏ để đáng xử lý

Giá quan sát trong cửa sổ 60 phút dao động CV 24,9% (trung vị 63 báo giá/cửa sổ), nhưng phần lớn là do các chuyển khác nhau: không chế quãng đường và thời lượng còn 18,6%, thêm điều kiện cùng giờ hầu như không giảm nữa (18,5%).

*Thị trường có động và động mạnh — nhưng model đã bắt được nhịp đó. Khoảng $\pm 30\%$ là ảnh phản chiếu của nhiễu ngang, không phải cái giá phải trả cho việc quan sát trễ. **Cập nhật** giá nhanh hơn không phải hướng đi.*

11.3 Model có hiểu cơ chế giá không

Nguồn: tuan_4/03_CETERIS_PARIBUS_VA_CAUSALITY.ipynb

Ba câu hỏi phải tách bạch, trộn lẫn là kết luận sai:

#	Câu hỏi	Đo bằng
A	Trời mưa thì giá thực tế đổi bao nhiêu?	Ghép cặp trên dữ liệu thật
B	Model dự đoán giá đổi bao nhiêu?	Cùng phép ghép cặp, chạy trên hybrid_pred
C	Model có hiểu rằng <i>mưa</i> gây ra thay đổi đó không?	Đổi riêng feature thời tiết (partial dependence)


Kết quả ở lag 5':

	Hiệu ứng mưa
A Thực tế	+10,30%
B Model dự đoán	+10,34%
C Partial dependence	+0,93%
Persistence (<i>mù thời tiết hoàn toàn</i>)	+8,99%

Ba con số này đều đúng, chúng trả lời ba câu khác nhau. Persistence — một con số không hề biết trời có mưa hay không — đã tái tạo 87% hiệu ứng. $\Rightarrow$ Model lấy đáp án qua đường tắt là giá quan sát trễ, không cần hiểu gì về mưa.

Phép thử quyết định: rút dần cái nạng ra.

Độ trễ	Thực tế	Model	Persistence	Khoảng trống	Model bù được
5'	+10,30%	+10,34%	+8,99%	1,31 điểm	103%
10'	+10,30%	+10,13%	+7,90%	2,40 điểm	93%
15'	+10,30%	+10,10%	+7,14%	3,16 điểm	94%
30'	+10,30%	+9,97%	+4,53%	5,77 điểm	94%



PU1_rut_cai_nang

Ở lag 30', giá trẻ chỉ còn giải thích +4,53% trong +10,30% — cái nạng gãy hơn một nửa. Model vẫn ra +9,97%, tức tự bù 94% phần thiếu.

Kết luận: model hiểu cơ chế, nhưng ưu tiên đường tắt khi đường tắt còn dùng được.

Đây là hành vi hợp lý của một model tối ưu MAE, không phải lỗi. Nhưng nó có hệ quả vận hành: ba tình huống rút nạng ra thì model sai —

16. **Câu what-if** — "nếu chiều mai mưa thì giá bao nhiêu?" Chưa có giá quan sát nào để chép.
17. **Horizon xa** — dự báo 30–60 phút tới.
18. **Thị trường mới** — chưa có lịch sử giá đối thủ.

Đúng ba tình huống mentor mô tả bằng cụm "*measure price như là kết quả của một thay đổi của yếu tố thị trường*".

Hệ quả cho việc encode causality: việc cần làm không phải *đạy* model cơ chế từ đầu, mà buộc nó dùng cơ chế nó đã có — train ở horizon dài hơn, hoặc phạt sự phụ thuộc vào giá trẻ. Rẻ hơn hẳn so với đổi kiến trúc.

Cái giá đã đo được: model bỏ hẳn feature giá quan sát kém 8% MAE (19.660đ vs 18.208đ) nhưng hiệu ứng cao điểm bật từ +2,4% lên +13,4%, khớp thực tế. Đó là đánh đổi độ chính xác lấy khả năng trả lời what-if — quyết định thuộc về team, không phải nhóm thực tập.

11.4 Khoảng bất đối xứng và CQR

Theo gợi ý mentor: khoảng hiện tại chia độ rộng khá đều cho hai phía, trong khi model bỏ sót phía giá cao nhiều hơn. Thử giữ độ rộng tương đương nhưng dành nhiều khoảng hơn cho phía giá cao.

Chẩn đoán đúng. Khoảng hiện tại $\hat{p} \cdot (1 \pm 30,07\%)$ đối xứng, còn sai lệch thực tế thì không: 7,64% giá thật vượt cận trên so với 2,55% thấp hơn cận dưới — tỷ lệ **3,00×**. Lệch nặng nhất ở band **>300k**: 11,62% vượt trên vs 4,59% dưới.

Nhưng cách sửa thì âm tính. Giữ tổng rủi ro 10%, chia lại thành **α dưới** / **α trên** qua 9 mốc:

Phương án	Coverage	Độ rộng TB	Lệch coverage giữa band
Đối xứng hiện tại	89,81%	72.637đ	8,62 điểm
Bất đối xứng 3%/7% (<i>hẹp nhất</i>)	89,81%	72.541đ ($-0,13\%$)	9,11 điểm
Bất đối xứng 5%/5% (<i>cân hai phía</i>)	89,92%	73.598đ ($+1,32\%$)	—

Không mốc chia nào vừa hẹp hơn vừa phủ tốt hơn đáng kể. Band **>300k** nằm trong khoảng 81,0–84,4% suốt cả lưới — chia lại rủi ro chỉ dịch khoảng cho **mọi** chuyển như nhau nên nhóm hụt nặng nhất vẫn hụt.

Vì sao âm tính. Khoảng là **nhân tính** chứ không cộng tính: chuyển 200k được $\pm 60,1k$ còn chuyển 400k được $\pm 120,3k$. Nó đã hấp thụ sẵn phần lớn độ lệch phải của phân phối giá, nên phần bất đối xứng còn lại quá nhỏ để một cặp hàng số khai thác. $\Rightarrow$ **Không lặp lại thí nghiệm này.**

Hướng đi được: cho độ rộng đổi theo từng chuyển. Dựng khoảng từ hai phân vị điều kiện **q05/q95** của quantile regression rồi hiệu chỉnh riêng từng phía (CQR):

Phương án	Coverage	Độ rộng TB	Lệch giữa band	Band >300k
Đối xứng hiện tại	89,81%	72.637đ	8,62 điểm	83,79%
Mondrian band + 3%/7%	89,84%	72.787đ ($+0,21\%$)	6,58 điểm	83,49%
CQR bất đối xứng 3%/7%	89,04%	74.954đ ($+3,2\%$)	1,55 điểm	88,03%

CQR là phương án **duy nhất** kéo được band **>300k** lên sát cam kết. Khác biệt bản chất: phương án hiện tại cấp độ rộng tỷ lệ thuận với giá dự đoán, còn CQR cấp theo **mức khó của từng chuyển**.

Quyết định còn treo: team chấp nhận khoảng rộng thêm bao nhiêu phần trăm để đổi lấy coverage đều giữa các band? Con số đó quyết định chọn Mondrian ($+0,21\%$, rẻ) hay CQR ($+3,2\%$, hiệu quả). Nguồn: [tuan_5/HUONG_3_KHOANG_BAT_DOI_XUNG.ipynb](#).

PHẦN IV — MỞ RỘNG

12. Acceptance model (Tầng 2)

II *Trạng thái: dừng ở v1 theo chỉ đạo mentor ("treat nó như một side objective"). Chờ dữ liệu bổ sung.*

12.1 Ràng buộc gốc

Dữ liệu không có nhãn accept/reject — `booking_or_completion_outcomes_generated = False`, 0/251 cột chứa outcome. Không có `customer_id` nên cũng không làm được personalized model.

12.2 Tám hướng đã thử và loại trừ

Đây là phần có giá trị nhất của nhánh này — mỗi hướng bị loại đều có bằng chứng số, không phải suy đoán:

Hướng	Vì sao loại	Bằng chứng
Supervised từ nhãn thật	Không có nhãn	0/251 cột
Unsupervised	Acceptance không tồn tại dạng ẩn	Quét toàn bộ 72 cột
Rule-based weak labeling	Vòng tròn logic	AUC 1,0000 → bỏ <code>price_gap</code> còn 0,4995
Proxy label từ cột khác	Không cột nào phù hợp	Rà hết 72 cột
PU learning	Cần ít nhất vài ca dương	Quan sát được 0 ca
Ước lượng cầu trực tiếp	Nội sinh	Hồi quy thô cho hệ số +0,40 — sai dấu
Biến công cụ (IV)	IV không hợp lệ	Bỏ biến giờ ⇒ hệ số lật từ -0,95 sang +0,36
Chỉ số Lerner	Cho ϵ vô lý	-33 đến -2,5
Đảo ngược quy tắc định giá	Surge sinh cơ học	Công thức <code>m = f(imbalance)</code>
SMM / indirect inference	Mô-men không chứa thông tin	Placebo test: tương quan 0,004

Hàng rule-based là bài học đắt nhất: AUC 1,0 trông như thành công lớn, thực chất là model đọc lại chính cái luật đã dùng để gán nhãn.

12.3 Hướng đã chọn — mô hình cấu trúc

Không train. Dùng lý thuyết lựa chọn rời rạc (McFadden):

```
def P_accept(gia_minh, gia_doithu, eps, P0=0.5, dich_WTP=0.0):  
    b = eps / (1 - P0)  
    a = np.log(P0 / (1 - P0))  
    z = a + b * (np.log(gia_minh / gia_doithu) - np.log1p(dich_WTP))  
    return 1 / (1 + np.exp(-z))
```

Bốn tham số — chỉ 2 là giả định:

Tham số	Nguồn	Giá trị	Kiểm chứng được?
gia_doithu	 Tầng 1	p	✓ MAE ~18.000đ
dich_WTP	 Đo từ dữ liệu	mưa +4,61% · giờ ±25%	✓ Từ hệ số nhân cân bằng
P_0	 Quy ước	0,5	✗ Cần hỏi mentor
ε	 Giả định	-2,0 (dải -1,2 → -3,0)	Neo bằng literature + MNL

12.4 Cách trình bày — dùng thay đổi tương đối

Phát hiện phương pháp luận đáng ghi: cách báo cáo quyết định độ vững của kết luận.

Cách báo cáo	Dao động khi P₀ chạy 0,30 → 0,70
Mức tuyệt đối	30,7 điểm ✗
Thay đổi tuyệt đối	9,3 điểm 
Thay đổi tương đối	3,1 điểm ✓

12.5 Kết quả

Đổi giá so với đối thủ	Chấp nhận (tương đối)
+5% / +10% / +20%	-10% / -19% / -35%
-5% / -10% / -20%	+10% / +21% / +42%

Ba kết luận vững trên toàn dải elasticity (3/3):

19. Giá cao hơn đối thủ → chấp nhận giảm

20. Mưa → chấp nhận tăng (+4,49 điểm %, ≈ tăng giá được 4,6% mà không mất khách)

21. **Giờ tác động mạnh hơn thời tiết ~8,3 lần** ⇒ chọn một tín hiệu định giá động thì chọn giờ

12.6 Kiểm chứng chéo bằng MNL

MNL 3 lựa chọn {không đi, mình, đối thủ} ràng buộc cả hai elasticity vào một β :

$$\varepsilon_{firm} = -\beta(1-s_1), \quad \varepsilon_{market} = -\beta s_0, \quad s_0 = (1-m)/(R-m)$$

Kết quả	
s₀ (khách không đi)	14,3% — trong khoảng hợp lý [5%; 30%]
β	3,500

MNL vs logit nhị phân	Khớp trong 3 điểm %
-----------------------	----------------------------

⚠ Tổ hợp $\epsilon_{\text{firm}} = -1,2 + \epsilon_{\text{market}} = -0,7$ cho $so = 41,2\%$ — không nhất quán, không được dùng đồng thời. Đây là loại mâu thuẫn mà logit nhị phân không phát hiện được.

12.7 Ngoài phạm vi tài liệu này

Repo còn một tầng quyết định giá đã dựng ở tuần 3 — tối ưu giá nên báo dựa trên phân phối dự đoán và chi phí biên. Tầng đó không nằm trong tài liệu này vì hai lý do: mentor không yêu cầu, và chiều của khuyến nghị phụ thuộc hoàn toàn vào chi phí biên — một tham số dự án không có.

Nội dung vẫn còn nguyên trong repo nếu cần tra:

Nơi	Nội dung
model/acceptance/KIEN_TRUC_CHOT.md	Hàm mục tiêu, ngưỡng đảo chiều, giá trị của việc tích phân trên phân phối
model/acceptance/07_chiphi_bien_va_uncertainty.ipynb	Cài đặt và backtest
model/acceptance/bang_tra_cuu_gia.csv	Bảng giá nên báo theo giờ × thời tiết

13. GAM và các thử nghiệm kiến trúc khác

13.1 GAM — bổ sung theo gợi ý mentor

Do trên tập test độ trễ 5 phút, 216.090 chuyển, so GAM với HistGB ở từng nhánh:

Nhánh	GBM	GAM	GAM tệ hơn
Giá cơ bản	14,58%	14,78%	+1,3% tương đối — gần như ngang
Hệ số nhân	1,42%	1,94%	+37,0% tương đối

Vì sao chênh lệch lớn thế: cho cây học lại phần dư của GAM → R^2 0,562 ở hệ số nhân vs **0,018** ở giá cơ bản.

⇒ Giá cơ bản là quan hệ cộng dồn thuần (GAM đủ sức); hệ số nhân có tương tác mà GAM không bắt được.

13.2 Transformed feature space

Theo gợi ý mentor: thêm tensor `te()` cho 3 cặp tương tác mạnh nhất → đóng được 52% khoảng cách (+30,7% → +14,7%).

13.3 Giá trị riêng của GAM

Không phải để thay model, mà để kiểm định thống kê: p-value tìm ra 4 feature không có ý nghĩa thống kê → bỏ khỏi feature contract.

Đáng chú ý: [weather_main](#) không ảnh hưởng giá cơ bản nhưng rất mạnh với hệ số nhân — xác nhận độc lập cho kết luận §3.3 bằng một phương pháp hoàn toàn khác.

13.4 Transformer

Trả lời câu hỏi "đã test thử neural network transformer chưa?"

Test rẻ trước (LightGBM, 400.000 mẫu train, đánh giá trên 314.368 chuyển test tháng 3):


Bộ feature	MAE	MAPE
A. Chỉ feature cơ bản (không lịch sử giá)	19.258đ	15,34%
B. + nhóm tổng hợp (mốc)	18.407đ	14,81%
C. + chuỗi 32 báo giá thô (bỏ nhóm tổng hợp)	18.397đ	14,81%
D. + cả hai	18.402đ	14,81%

Đọc bảng:

- Lịch sử giá có giá trị thật — bỏ đi tệ hơn 4,4%
- Nhưng chuỗi thô và nhóm tổng hợp cho kết quả y hệt (−0,1%)
- Nhét cả hai vào không giúp gì (−0,0%)

⇒ Nhóm tổng hợp [mean/std/slope](#) + giá quan sát gần nhất đã là thống kê đủ cho chuỗi. Transformer đọc chuỗi sẽ không có gì mới để đọc.

Kiến trúc đã dựng ([transformer/kaggle_transformer.ipynb](#), ~90.000 tham số):



Dự đoán hai đầu ra rồi nhân lại giống kiến trúc Hybrid, train riêng từng tháng (lịch sử giá reset theo tháng, gộp lại là rò rỉ). Notebook dựng chuỗi bằng [searchsorted](#) và có [assert](#) chống rò rỉ: chỉ lấy báo giá có [ts <= cutoff](#) — kiểm tra chạy qua, 99,96% mẫu đủ 32 báo giá.

Kết quả chạy đầy đủ trên Kaggle ([transformer/pricing-tranfomer.ipynb](#), Tesla T4):

Tháng	MAE	MAPE	R ²	n
1	17.846đ	14,87%	0,7341	315.360

2	17.868đ	14,76%	0,7351	234.632
3	18.275đ	14,76%	0,7287	314.368
Gộp	18.008đ	14,80%	0,7326	864.360

So với Hybrid — hoà, không phải thắng:

	Hybrid	Transformer	Chênh
MAE	18.048đ	18.008đ	−0,22% (<i>transformer tốt hơn</i>)
MAPE	14,74%	14,80%	+0,06 điểm (<i>transformer tệ hơn</i>)
Tham số	—	90.792	
Thời gian train	~9 ph (CPU)	~35 ph (GPU T4)	

⚠ Notebook tự kết luận "*Transformer THẮNG Hybrid 0,22%*" vì chỉ số MAE. Đọc đủ hai metric thì đây là hoà: transformer tốt hơn ở sai số tuyệt đối, tệ hơn ở sai số tương đối. MAE ưu ái chuyển đất, MAPE ưu ái chuyển rẽ — hai metric đi ngược nhau nghĩa là hai model chỉ khác nhau ở cách phân bổ sai số, không phải một cái giỏi hơn.

Chênh lệch 0,22% cũng nằm gọn trong dải 1,9% giữa 4 thuật toán cây (§7.2).

Theo band giá — điểm yếu giống hệt Hybrid:

Band	n	MAE	MAPE
<50k	10.441	6.054đ	13,84%
50–100k	259.587	11.785đ	14,34%
100–150k	412.662	18.288đ	15,04%
150–200k	152.123	25.421đ	15,01%
200–300k	28.261	33.496đ	14,70%
>300k	1.286	64.283đ	18,06%

Band **>300k** vẫn tệ nhất (18,06%, so với 18,55% của Hybrid) — cùng một chỗ hỏng, kiến trúc khác hẳn cũng không sửa được.

Kết luận: transformer đọc thẳng chuỗi 32 báo giá không moi thêm được thông tin nào so với ba con số [mean/std/slope](#). Đây đúng là điều test rẽ đã dự đoán. Kết quả này củng cố §7.5: nút thắt là dữ liệu, không phải sức chứa của model.

Không đưa vào pipeline. Đôi lấy 0,22% MAE (và mất 0,06 điểm MAPE) bằng một model cần GPU, gấp 4 lần thời gian train, và phải lưu thêm thống kê chuẩn hoá để phục vụ — không đáng.

13.5 Trọng số cho chuyển hiểm — kết quả âm tính

Theo gợi ý mentor: giữ model hiện tại làm mốc, đặt trọng số lớn hơn cho chuyển hiểm rồi đo xem hai nhóm khó giảm bao nhiêu và toàn tập phải đánh đổi bao nhiêu.

Lưới $w \in \{1, 2, 3, 5, 10, 20\} \times 3$ cách gán "chuyển hiểm" (>15 km · $>300k$ · cả hai), 48 lượt train, chỉ train lại nhánh giá cơ bản. Điểm neo: $w = 1$ cho MAPE 14,6496%, trùng model mốc tới bốn chữ số thập phân.

Cách gán	w	>15 km	>300k	Toàn tập
— (mốc)	1	17,52%	23,67%	14,65%
Theo giá	10	21,69% (−4,17)	20,44% (+3,23)	14,71% (−0,06)
Theo quãng đường	20	18,51% (−0,98)	23,53% (+0,14)	14,66% (−0,01)

Dấu trong ngoặc là chênh so với mốc, **dương là tốt lên**. Mọi chênh lệch kèm bootstrap CI 95%.

Hai điều rút ra:

Gán theo quãng đường không cứu được chính nhóm nó nhắm tới. Nhóm >15 km chỉ có 14.206 dòng train và vốn rất nhiều, nên tăng trọng số chỉ khuếch đại nhiều — nhóm này xấu đi đơn điệu theo w ở cả ba cách gán.

Hai nhóm hiểm kéo ngược nhau. Gán theo giá là cách duy nhất kéo $>300k$ xuống, nhưng đổi lại >15 km mất 4,17 điểm — phần mất lớn hơn phần được. Không có một mức trọng số nào cải thiện đồng thời cả hai.

⇒ **Loại**. Nguồn: [tuan_5/HUONG_1_THAY_DOI_WEIGHT.ipynb](#).

13.6 Ghép GAM–GBM theo quãng đường — phương án chốt

§13.1 cho thấy GAM chỉ thắng ở nhánh giá cơ bản của chuyển dài. Trước khi ghép phải kiểm lợi thế đó có ổn định không, vì nhóm >15 km chỉ có 660 chuyển test.

Điều kiện tiên quyết. Dựng 9 lát chia train/test theo thời gian: **8/9 lát GAM thắng rõ ở >15 km** (CI loại trừ 0), **0 lát GBM thắng rõ**. Không lát nào đảo chiều ⇒ lợi thế là thật.

Dạng ghép. Trộn tuyến tính, trọng số GAM tăng dần theo quãng đường, chỉ áp lên nhánh giá cơ bản:

$$\hat{p} = (1 - \alpha(d)) \cdot \hat{p}_{\text{GBM}} + \alpha(d) \cdot \hat{p}_{\text{GAM}}$$

$$\begin{aligned} \alpha(d) &= 0 && \text{nếu } d \leq d_0 \\ &= (d - d_0)/(d_1 - d_0) \cdot \alpha_{\text{max}} && \text{nếu } d_0 < d < d_1 \\ &= \alpha_{\text{max}} && \text{nếu } d \geq d_1 \end{aligned}$$

Tham số chốt $d_0 = 6\text{ km}$, $d_1 = 14\text{ km}$, $\alpha_{\text{max}} = 0,8$, dò trên **2026-01** rồi đánh giá trên hai tháng chưa đựng tới (137.250 chuyến). $\alpha(d)$ liên tục nên giá không nhảy bậc — khách đi 13,9 km và 14,1 km không nhận giá lệch hẳn nhau.

Nhóm	n	GBM	Ghép	Chênh	CI 95%
>15 km	428	18,12%	15,61%	+2,50	[+1,73, +3,36]
>300k	548	24,04%	22,49%	+1,55	[+1,04, +2,09]
Toàn tập	137.250	14,630%	14,616%	+0,014	[+0,01, +0,02]

Trên tập test đầy đủ với nhóm cố định (216.090 chuyến): >15 km 17,52% → **15,40%**, >300k 23,67% → **22,24%**, toàn tập 14,65% → **14,64%**. Cả bốn cột đều có CI loại trừ 0.

Vì sao không dùng thẳng GAM. GAM đơn lẻ tốt hơn ghép ở cả hai nhóm hiếm (15,37% và 22,03%) nhưng toàn tập xấu đi **0,24 điểm** — đổi 216.090 chuyến lấy 1.500 chuyến là lỗ.

Cơ chế, không phải may rủi. Cây không ngoại suy được: qua nhát cắt cuối cùng, dự đoán thành hằng số. Vùng >20 km chỉ chiếm **0,06%** tập train nên gần như không có nhát cắt nào ở đó. Đo bằng sai lệch có dấu: nhóm >25 km có giá thật TB 463.286đ, GBM báo 328.995đ (**−29,0%**), GAM báo 462.720đ (−0,1%), ghép 439.039đ (−5,2%). GAM khớp hàm trơn nên vẫn đi lên khi ra ngoài vùng dày dữ liệu.

⇒ **Nhận.** Nguồn: [tuan_5/HUONG_2_GAM_GBM.ipynb](#), [tuan_5/XU_HUONG_DU_DOAN.ipynb](#).

13.7 Bảng tổng hợp các hướng đã thử

Ghi rõ để sau này không ai phải thử lại:


Đã thử	Kết quả
4 thuật toán (XGBoost / LightGBM / HistGB / GAM)	Chênh nhau 1,9%
Neural network multi-task (MLP)	Thua GBM
Optuna 40 trial × 3 tháng	+2 VND
Ném hết 49 cột + feature weights	+6 VND
Transformer đọc chuỗi (test rề)	Không hơn nhóm tổng hợp
Transformer chạy đầy đủ (90.792 tham số, GPU T4)	MAE −0,22% · MAPE +0,06 điểm — hoà
5 cách hiệu chỉnh khoảng × 7 nhóm	Tốt nhất −0,43%
GBM dự đoán độ khó từng chuyến	Tương quan hạng 0,053
Trọng số cho chuyến hiếm, 48 lượt train (§13.5)	Âm tính — hai nhóm hiếm kéo ngược nhau
Ghép GAM–GBM theo quãng đường (§13.6)	>15 km +2,50 điểm · >300k +1,55 · toàn tập không xấu đi

Tất cả **trừ hàng cuối** đều chỉ về cùng một kết luận: đã chạm trần dữ liệu (§7.5). Ghép GAM–GBM không phá được trần đó — toàn tập gần như đứng yên — nhưng nó cho thấy trần là của **toàn tập**, còn từng nhóm thì vẫn còn dư địa nếu đổi dạng hàm thay vì đổi trọng số.

14. Đối chiếu Boston

Bộ dữ liệu Uber/Lyft Boston làm ở tuần 1, trước khi mentor gửi dữ liệu TP.HCM. Giữ lại để đối chiếu — nhiều kết luận tuần 2–3 có so với Boston (biên độ surge, hệ số co giãn).

Thư mục	Nội dung
boston_data/analysis/	11 notebook EDA
boston_data/model/	5 notebook model
boston_data/docs/	9 tài liệu



F2_boston_vs_hcm

⚠ Hai bộ dữ liệu khác nhau về thị trường, đơn vị tiền tệ và cơ chế surge. Đối chiếu chỉ dùng để **kiểm tra tính hợp lý về bậc độ lớn**, không dùng để suy diễn kết luận chéo.

PHẦN V — VẬN HÀNH

15. Tái lập

15.1 Môi trường

Python	3.11.8
Thư viện chính	pandas, numpy, scikit-learn, lightgbm, xgboost, pygam, matplotlib, scipy
Cài đặt	pip install -r requirements.txt
Chi tiết	SETUP.md

15.2 Thứ tự chạy chuẩn

1. model/00_chuan_bi_du_lieu	~2,5 ph	→ data/hcm_train_ready.parquet
2. model/train/01-03	~9 ph	→ HistGB/, LightGBM/, XGBoost/
3. model/train/04-05	~13 ph	→ GAM/
4. model/train/06		→ QuantileLGBM/
5. model/train/07_sinh_du_lieu_UQ		→ evaluation/uq_pred_*.parquet
6. model/evaluation/01-09		→ đánh giá + chẩn đoán
7. model/uncertainty/00-06		→ khoảng bất định
8. model/acceptance/00_TONG_HOP	~1 ph	→ Tầng 2 (đọc lập)
9. tuan_4/00-06		→ tổng hợp tuần 4

Phụ thuộc quan trọng: bước 8 chỉ cần [hcm_train_ready.parquet](#). Các notebook [tuan_4/](#) cần [evaluation/uq_pred_{calibration,test}.parquet](#) từ bước 5.

15.3 Dung lượng và thời gian

Hạng mục	Dung lượng	Sinh lại mất
data/synthetic_data/	459,5 MB	Không sinh lại được — dữ liệu gốc
data/hcm_train_ready.parquet	368,6 MB	~2,5 ph
evaluation/*.parquet	~438 MB	~25 ph
Model .joblib	202 MB	~21 ph
docs/hinh_anh/	17,6 MB	Theo notebook sinh ra

15.4 Demo trình bày

[demo/index.html](#) — mở bằng cách nhấp đúp, không cần cài gì và không cần server. Demo chạy tập test qua model và mô phỏng từng chuyến trên bản đồ: giá dự đoán, khoảng tin cậy, rồi giá thật khi xe tới nơi.

Demo đọc [demo/du_lieu/chuyen.json](#) (900 chuyển đại diện + 327 chuyển >300k, lấy từ tập test) và [cauhinh.json](#) (tham số **q** cho 3 mức tin cậy × 6 band, hiệu chỉnh trên tập calibration). Phải sinh lại hai file này mỗi khi model được train lại, nếu không demo sẽ hiển thị dự đoán cũ.

Kịch bản trình bày 4 bước và danh sách hạn chế cần nói trước nằm ở [demo/README.md](#) và [THANH_PHAM_4_TUAN.md](#).

16. Kiểm thử và biên bản chạy lại

Ngày 10/08/2026 đã chạy lại toàn bộ 59 notebook để kiểm tính tái lập. Kết quả:

Notebook chạy lại thành công	59/59
Hình được vẽ lại	120/121
Số liệu khớp báo cáo tuần 3	✓ (lệch ở hàng thập phân)
Artifact không sinh lại được	7 → đã vá

Lỗi hồng đã vá: 7 artifact không có notebook nào sinh ra chúng. Đã bổ sung [train/07_sinh_du_lieu_UQ.ipynb](#), đối chiếu với bản cũ trước khi ghi đề để đảm bảo công thức dựng lại đúng.

Chi tiết: [BIEN_BAN_CHAY_LAI.md](#).

Nguyên tắc rút ra: mọi artifact phải có notebook sinh ra nó. Artifact mô côi là nợ kỹ thuật — khi cần sinh lại thì không ai biết công thức.

17. Quy ước repo

Quy ước	Ví dụ
Số thứ tự = thứ tự chạy	01_train_gia_co_ban → 02_train_he_so_nhan
00_ = điểm vào / tổng quan	00_TONG_QUAN, 00_chuan_bi_du_lieu
00_TRINH_BAY_ = bản rút gọn để trình bày	00_TRINH_BAY_model_gia
90+ = tiện ích, không thuộc luồng chính	90_sinh_hinh_bao_cao_tuan2
_archive/ = bản cũ, không còn dùng	
Tiền tố hình = notebook sinh ra nó	CP* ← 14_ceteris_paribus

Tiền tố hình đã dùng (không được trùng): A AC AT B BG BM BT CD CG CP CQ CT D E F GA KT LIT M MD MG MNL MT O PL PM PU QD QR SS T TC TF TH TK TQ TT U UA UQ V VQ.

Mỗi thư mục notebook có [README.md](#) liệt kê từng file — sinh tự động từ tiêu đề trong notebook nên không lệch.

18. Rủi ro, giới hạn và việc còn nợ

18.1 Ba giới hạn thật

#	Giới hạn	Hệ quả
1	Dữ liệu synthetic	Mọi kết luận mô tả simulator, không phải thị trường thật
2	Không có nhãn accept/reject	Tầng 2 là mô phỏng dưới giả định , không phải model học
3	Model đã chạm sàn nhiều dữ liệu	Không cải thiện được độ chính xác bằng dữ liệu hiện có

⚠ Số trích từ literature (Cohen 2016) ghi từ trí nhớ, chưa đối chiếu bản gốc.

18.2 Cách phát biểu đúng khi báo cáo

Điểm	Phát biểu đúng
Tầng 2 không phải ML	"Model cấu trúc từ lý thuyết lựa chọn rồi rạc, không train"
Kết quả phụ thuộc giả định	"Dưới giả định $\varepsilon \in [-1,2; -3,0] \dots$ "
P₀ chưa kiểm chứng	"Con số tuyệt đối phụ thuộc giả định $P_0 = 0,5$ "
Model tĩnh	"Chưa tính phản ứng của đối thủ"
Dữ liệu synthetic	"Mô tả hành vi bộ sinh dữ liệu, không phải thị trường TP.HCM"

18.3 Việc nên làm tiếp, theo thứ tự

Hướng	Chi phí	Vì sao
Gộp ghép GAM–GBM vào pipeline chính	vài giờ	Đã kiểm chứng ở §13.6, hiện còn nằm rồi ở tuan_5/ . Không train lại
~Bật Mondrian theo quãng đường~	✓ đã làm	Lệch coverage giữa nhóm 12,6 → 2,5 điểm, tốn thêm 0,04% độ rộng
CQR bất đối xứng	vừa	Cách duy nhất kéo band >300k lên 88,03% (§11.4). Chỉ làm nếu team chấp nhận +3,2% độ rộng
Encode causality	vừa	Không phải để tăng độ chính xác, mà để trả lời được what-if (§11.3)

~~Đặt trọng số cho chuyển hiểm~~	—	Âm tính, 48 lượt train (§13.5). Hai nhóm hiểm kéo ngược nhau
~~Khoảng bất đối xứng bằng cặp hằng số~~	—	Âm tính, 9 mốc chia rủi ro (§11.4). Khoảng nhân tính đã hấp thụ sẵn độ lệch phải
~~Thêm feature thị trường~~	—	Đổ vào tầng đã đạt MAPE 1,42%. Giá cuối gần như không đổi
~~Tinh chỉnh siêu tham số~~	—	Optuna 40 trial → +2 VND

18.4 Câu hỏi chặn tiến độ — gửi mentor

#	Câu hỏi	Mở khoá	Ưu tiên
1	Dữ liệu thật có mức nhiễu báo giá như bộ synthetic không? Các chuyển giống hệt nhau vẫn lệch giá cơ bản ~18,6%	Toàn bộ kế hoạch improve model	●
2	Team ưu tiên độ chính xác hay khả năng giải thích ?	Hướng đi kỹ thuật (§11.3)	●
3	% khách xem giá rồi không đặt (so) + thị phần?	Chốt $\beta \Rightarrow$ hết phải giả định elasticity	●
4	"Encode causality" — ràng buộc đơn điệu, feature biến đổi, hay mô hình cấu trúc?	Việc còn nợ duy nhất	
5	Ngày lễ — dữ liệu thật có hiệu ứng này không?	Phần ngày lễ của cấu thành giá	
6	Surge có ngưỡng nhảy bậc không?	Mở khoá RD $\Rightarrow \epsilon$ thật từ dữ liệu lịch sử	

Nếu chỉ hỏi được 2 câu: hỏi câu 1 và câu 2. Câu 1 đứng đầu vì §7.5 cho thấy MAPE 14,65% đã gần sàn của bộ dữ liệu. Nếu dữ liệu thật cũng nhiễu như vậy thì mọi nỗ lực improve model là vô ích và team nên chuyển toàn bộ công sức sang khả năng giải thích. Nếu dữ liệu thật sạch hơn thì toàn bộ kết luận này cần đo lại.

18.5 Điều kiện để nâng cấp kiến trúc

Kiến trúc hiện tại là tối ưu với dữ liệu đang có. Chỉ nâng cấp khi có thêm dữ liệu:

Nếu có	Thì đổi thành	Lợi ích
so + thị phần	MNL hiệu chỉnh bằng số thật	Chốt $\beta \Rightarrow$ hết giả định elasticity
Ngưỡng nhảy bậc surge	Regression Discontinuity	ε thật, không cần thí nghiệm
outcome cuốc	Tầng 2 $\rightarrow$ supervised thật	ε ước lượng thay vì giả định
Thí nghiệm giá ngẫu nhiên	Elasticity nhân quả sạch	Chuẩn vàng
Nghi ngờ giả định IIA	MNL $\rightarrow$ Nested Logit	Xử lý thay thế không đối xứng

PHỤ LỤC

A. Bản đồ notebook

Thư mục	Số notebook	Nội dung
analysis/	22	Cấu phần (i) — yếu tố ảnh hưởng giá
model/train/	7	Huấn luyện
model/evaluation/	10	Đánh giá + chẩn đoán
model/uncertainty/	7	Cấu phần (iii)
model/acceptance/	11	Tầng 2–3
tuan_4/	7	Tổng hợp tuần 4
transformer/	2	Thử nghiệm
boston_data/	16	Tuần 1, đối chiếu

Notebook nên đọc trước nếu tiếp quản:

Thứ tự	Notebook	Vì sao
1	tuan_4/00_TONG_HOP	Bức tranh toàn cục, tự tính lại mọi số
2	model/99_TONG_QUAN_TOAN_DU_AN	Chạy 1 phút ra hết số chính
3	model/evaluation/09_chan_doan_model	Model sai ở đâu
4	model/acceptance/KIEN_TRUC_CHOT.md	Kiến trúc tầng 2–3

B. Chỉ mục hình theo tiền tố

Tiền tố	Notebook sinh ra	Chủ đề
---------	------------------	--------

CD	evaluation/09	Chẩn đoán model
CG	tuan_4/04	Cấu thành giá
CP	analysis/14	Ceteris paribus
CT	evaluation/10	Sai số chi tiết
GA	evaluation/08	GAM
KT	model/99	Kiến trúc tầng
MD	uncertainty/01	Mondrian
PU	tuan_4/03	Phản ứng giá / causality
QD	tuan_4/02	Quyết định improve hay giảm uncertainty
TH	uncertainty/06	Thu hẹp khoảng
TK	tuan_4/00	Tổng kết tuần 4
TT	uncertainty/05 , tuan_4/01	Theo thời gian
VQ	uncertainty/00	Trực quan UQ

C. Nhật ký đỉnh chính

Phần này ghi lại các kết luận đã phải sửa. Giá trị của nó: người sau biết chỗ nào từng trơn trượt, và người đọc thấy được kết luận nào đã qua kiểm chứng nhiều vòng.

C.1 "CQR có coverage điều kiện tốt nhất"

Kết luận sai	CQR tốt nhất về coverage điều kiện
Nguyên nhân	Chỉ so với QR thô, chưa so với conformal chuẩn hoá và Mondrian
Kết luận đúng	Không phương pháp nào thắng tuyệt đối trên cả 3 chiều. Mondrian tốt hơn CQR cả về công bằng (0,81 vs 1,09) lẫn độ rộng
Bài học	So sánh phải đủ bộ đối thủ trước khi tuyên bố "tốt nhất"

C.2 "Model bám giá quan sát chứ không hiểu cơ chế"

Kết luận sai	Phát biểu quá nặng, dựa trên partial dependence ở lag 5' (+0,93%)

Nguyên nhân	Chưa tách bạch ba câu hỏi A/B/C (§11.3); chưa thử rút feature giá trẻ ra
Kết luận đúng	Model hiểu cơ chế , nhưng ưu tiên đường tắt khi đường tắt còn dùng được. Ở lag 30' nó tự bù 94%
Bài học	Một phép đo trả lời đúng một câu. Đổi câu hỏi thì phải đổi phép đo

C.3 Đơn vị quote_duration

Kết luận sai	Trần thông tin của giá cơ bản = 14,84%, phù 72% dữ liệu
Nguyên nhân	quote_duration tính bằng giây nhưng bị dùng như phút → ô không chế thành 5 giây thay vì 5 phút
Phát hiện nhờ	Nhãn trên hình in ra "1125–1130 phút"
Kết luận đúng	Trần = 14,98% , phù 99% dữ liệu. Kết luận không đổi mà còn chắc hơn
Bài học	Vẽ hình ra và đọc nhãn — một con số vô lý trên nhãn lộ ra lỗi mà bảng số giấu kín

C.4 GAM so với cây ở §13.1

Bản trước ghi GAM tệ hơn **+0,5%** ở nhánh giá cơ bản và **+30,5%** ở nhánh hệ số nhân. Tính lại trực tiếp từ [pred_gam.parquet](#) và [pred_gia_co_ban.parquet](#) trên tập test độ trễ 5 phút cho **+1,3%** và **+37,0%**. Hai con số cũ không ghi rõ tập đo nên không tái lập được; bản hiện tại ghi rõ tập và số lượng chuyển.

Kết luận định tính **không đổi**: giá cơ bản là quan hệ cộng dồn thuần nên GAM theo kịp, còn hệ số nhân có tương tác mà GAM không bắt được.

C.5 "Phải improve model"

Kết luận chưa đủ	Đường giảm uncertainty đã cạn ⇒ phải improve model
Bổ sung	Đường improve model cũng cạn trên bộ dữ liệu này (§7.5)
Kết luận đúng	Ràng buộc thật sự là dữ liệu , không phải model
Bài học	Loại trừ được một đường không có nghĩa đường còn lại đi được

C.6 "Lợi thế của GAM ở nhóm giá cao là +4,02 điểm"

Kết luận sai	GAM hơn Hybrid + 4,02 điểm ở nhóm >300k
Nguyên nhân	Mỗi model tự chia nhóm theo giá chính nó dự đoán . Nhóm >300k khi đó chỉ còn 327 chuyển theo giá Hybrid và 330 theo giá GAM — chỉ 224 chuyển có mặt ở cả hai, tức hai model được chấm trên hai tập khác nhau
Kết luận đúng	Chia nhóm theo giá thật (869 chuyển, độc lập với mọi model) cho + 1,65 điểm . Lợi thế bị phồng 2,45 lần
Bài học	Nhóm dùng để so sánh phải độc lập với đầu ra của model. Ngoại lệ có chủ ý: đánh giá coverage vẫn chia theo giá dự đoán , vì khoảng tin cậy là lời hứa đưa ra khi chưa biết giá thật

Nguồn: [tuan_5/06_NHOM_CO_DINH.ipynb](#). Mọi bảng so sánh model trong tài liệu này đã dùng nhóm cố định.

Tài liệu này tái lập được hoàn toàn. Mọi con số đều có notebook sinh ra. Chỗ nào là giả định đều được đánh dấu.